

Analyse Karlodinium

Illumina

Nombre de reads avant l'assemblage : 666 590 146

	Assemblage 1	Assemblage 2	Assemblage 3	Assemblage 4
Echantillon	Tous	Retrait des 2, 5, 8, 13, 14 et 18	Retrait des 2, 5, 8, 13, 14 et 18	Retrait des 2, 5, 8, 13, 14 et 18
Date	?	18 Novembre 2024	28 Novembre 2024	01 Janvier 2025
Version de Trinity	2.8.5	2.8.5	2.8.5	2.15.2
Nombre de transcrits	64 245	936 535	615 933	639 081
Longueur maximum	-	-	91 707	52 209
Longueur minimal	-	-	176	175
Longueur moyenne (N50)	-	-	764	783
GC%	-	-	48.00%	48.00%

Analyse qualité

Pour l'analyse qualité des assemblages, plusieurs outils bioinformatiques ont été utilisés afin de valider l'intégrité et la fiabilité des résultats obtenus.

- **BUSCO** (Benchmarking Universal Single-Copy Orthologs) évalue la qualité de l'assemblage en identifiant des orthologues universels présents dans un large éventail d'organismes **eucaryotes**. Il permet de mesurer la complétude de l'assemblage en quantifiant le pourcentage de gènes conservés et complets. Cela permet d'estimer la **qualité générale** de l'assemblage et de détecter d'éventuelles pertes d'information génomique.
 - Dans notre cas, l'analyse a été réalisée à partir de la base de données **eucaryote**.
- L'outil **Bowtie** permet de mesurer la qualité des alignements, en fournissant une analyse détaillée des correspondances entre les reads et les séquences de référence. Cela donne une évaluation de la **précision de l'assemblage**, ainsi que des informations sur les éventuels biais d'alignement ou erreurs de séquençement.
 - Cet alignement **pairwise** a été effectué entre les résultats d'assemblage de **Trinity** et les lectures brutes **R1** et **R2** des échantillons **Karmit**.
- Le **BLAST** (Basic Local Alignment Search Tool) a permis d'aligner les reads issus de chaque assemblage contre une base de données de **protéines**. Cette étape permet d'identifier les homologues protéiques connus et d'analyser les **fonctions possibles** des séquences obtenues. L'alignement contre une banque de données comme **UniProt** aide à évaluer la validité biologique des assemblages en comparant les protéines assemblées à celles déjà caractérisées. Cela permet de confirmer la **pertinence de l'assemblage** en termes de codage pour des protéines fonctionnelles.
 - Ici, nous avons utilisé la base de données [UniProt](#).

Assemblage n°1

La réalisation de ce premier assemblage a été difficile. J'ai dû relancer la commande plusieurs fois et supprimer des fichiers pour parvenir à son terme.

BUSCO

Statistique	Pourcentage	Nombre de BUSCOs	Interprétation
BUSCOs complets (C)	3.1%	8	Très faible proportion de BUSCOs complets, indiquant un assemblage de faible qualité.
- BUSCOs complets et en copie unique (S)	3.1%	8	Tous les BUSCOs complets sont en copie unique.
- BUSCOs complets et dupliqués (D)	0.0%	0	Aucun BUSCO complet dupliqué, ce qui n'est pas inhabituel pour un assemblage défaillant.
BUSCOs fragmentés (F)	9.4%	24	Une petite proportion de BUSCOs fragmentés.
BUSCOs manquants (M)	87.5%	223	La majorité des BUSCOs attendus sont absents, signalant une qualité très insuffisante.
Nombre total de groupes BUSCO recherchés	-	255	Total des BUSCOs inclus dans l'analyse.

Conclusion :

Les résultats BUSCO sont très peu concluants. Cet assemblage ne permet pas une analyse pertinente. Il est inutile d'approfondir les investigations avec ces données.

Assemblage n°2

Le nombre de reads produit est élevé par rapport à ce qui est rapporté dans la littérature. On s'attend à détecter environ **160 000 gènes** après assemblage.

BUSCO

Statistique	Pourcentage	Nombre de BUSCOs	Interprétation
BUSCOs complets (C)	86.3%	220	Une proportion élevée de BUSCOs complets, montrant un assemblage de meilleure qualité.
- BUSCOs complets et en copie unique (S)	40.8%	104	Bonne spécificité dans la moitié des BUSCOs complets.
- BUSCOs complets et dupliqués (D)	45.5%	116	Taux de duplication élevé, ce qui peut indiquer une redondance dans l'assemblage.
BUSCOs fragmentés (F)	7.1%	18	Proportion modérée de BUSCOs fragmentés.
BUSCOs manquants (M)	6.6%	17	Faible proportion de BUSCOs absents.
Nombre total de groupes BUSCO recherchés	-	255	Total des BUSCOs inclus dans l'analyse.

Conclusion :

Les résultats BUSCO sont intéressants mais doivent être interprétés avec prudence compte tenu du nombre élevé de reads produits.

Assemblage n°3

Aucun problème rencontré lors de cet assemblage, mais le nombre de reads reste élevé par rapport à la littérature.

BUSCO

Statistique	Pourcentage	Nombre de BUSCOs	Interprétation
BUSCOs complets (C)	77.3%	197	Résultats acceptables, mais inférieurs à l'assemblage n°2.
- BUSCOs complets et en copie unique (S)	47.1%	120	Meilleure proportion de BUSCOs uniques comparée à l'assemblage précédent.
- BUSCOs complets et dupliqués (D)	30.2%	77	Taux de duplication réduit par rapport à l'assemblage n°2.
BUSCOs fragmentés (F)	6.3%	16	Proportion faible de BUSCOs fragmentés.
BUSCOs manquants (M)	16.4%	42	Augmentation du nombre de BUSCOs manquants par rapport à l'assemblage n°2.
Nombre total de groupes BUSCO recherchés	-	255	Total des BUSCOs inclus dans l'analyse.

Bowtie2

Statistique	Pourcentage	Nombre de reads	Interprétation
Total des reads	-	333295073	Nombre total de reads analysés.
Reads appariés	100.00%	333295073	Proportion des reads appariés.
- Alignés concordamment 0 fois	23.76%	79197353	Reads appariés mais non alignés concordamment.
- Alignés concordamment exactement 1 fois	37.99%	126603727	Reads alignés exactement une fois.
- Alignés concordamment plus d'une fois	38.25%	127493993	Reads alignés plus d'une fois.
Alignement concordant 0 fois	23.76%	79197353	Paires non alignées concordamment.
- Alignées discordamment 1 fois	30.48%	24142634	Paires alignées discordamment une fois.
Paires non alignées concordamment ni discordamment	-	55054719	Paires n'ayant pas d'alignement (concordant ou discordant).
Mates constituant les paires non alignées	-	110109438	Mates qui composent les paires non alignées.
- Alignés 0 fois	39.44%	43428872	Mates non alignés.
- Alignés exactement 1 fois	6.82%	7513357	Mates alignés exactement une fois.
- Alignés plus d'une fois	53.73%	59167209	Mates alignés plus d'une fois.
Taux d'alignement global	93.48%	-	Proportion des reads alignés globalement.

Conclusion :
L'assemblage présente une qualité raisonnable avec un taux de duplication réduit, mais des lacunes persistantes.

Assemblage n°4

Cet assemblage donne des résultats similaires au précédent, avec un nombre élevé de reads.

BUSCO

Statistique	Pourcentage	Nombre de BUSCOs	Interprétation
BUSCOs complets (C)	77.2%	197	Résultats pratiquement identiques à l'assemblage n°3.
- BUSCOs complets et en copie unique (S)	43.1%	110	Proportion de BUSCOs uniques légèrement inférieure.
- BUSCOs complets et dupliqués (D)	34.1%	87	Taux de duplication comparable à l'assemblage précédent.
BUSCOs fragmentés (F)	6.3%	16	Nombre stable de BUSCOs fragmentés.
BUSCOs manquants (M)	16.5%	42	Résultats constants pour les BUSCOs absents.
Nombre total de groupes BUSCO recherchés	-	255	Total des BUSCOs inclus dans l'analyse.

Bowtie2

Statistique	Pourcentage	Nombre de reads
Total des reads	-	333295073
Reads appariés	100.00%	333295073
- Alignés concordamment 0 fois	23.60%	78642271
- Alignés concordamment exactement 1 fois	30.90%	102974715
- Alignés concordamment plus d'une fois	45.51%	151678087
Alignement concordant 0 fois	-	78642271
- Alignées discordamment 1 fois	24.43%	19211385
Paires non alignées concordamment ni discordamment	-	59430886
Mates constituant les paires non alignées	-	118861772
- Alignés 0 fois	37.23%	44249791
- Alignés exactement 1 fois	5.55%	6594469
- Alignés plus d'une fois	57.22%	68017512
Taux d'alignement global	93.36%	-

Conclusion :
Les résultats obtenus sont presque identiques à ceux de l'assemblage n°3. Cela suggère que, avec les paramètres actuels de Trinity, il est peu probable d'obtenir de meilleures performances sans modifier le script.

MinION

Paramètre	Run 1	Run 2	Run 3	Run 4	Run 5
Dates	30 Septembre 2024	30 Septembre 2024	22 Novembre 2024	26 Novembre 2024	26 Novembre 2024
Type MinION	-	-	-	-	Fongl
Basecalling	Oui	Oui	Oui	Oui	Oui
Nombre de reads	230 036	225 972	5 963 928	4 873 094	317 695

Assemblage RATTLE

Run 1

Étape	Nombre de reads
Avant assemblage	230 036
Après correction	157 426
Après polissage	404

Analyse de qualité via BUSCO

Résultat :

100% des gènes sont manquants. Cela signifie que ces orthologues sont absents ou que les transcriptions obtenues sont trop incomplètes pour être détectées.

Concaténation des Runs

- **Nombre total de reads** : 11 610 725

1er Test

Méthode :

Exécution du code effectué pour le run 1 sur le fichier concaténé.

Problème :

- Segmentation fault lors de l'étape de clusterisation.

Solutions tentées :

- Variation de la mémoire et du nombre de CPU alloués pour le job.

Résultat :

- Échec.
-

2ème Test

Méthode :

Réaliser la clusterisation sur les fichiers séparés, puis effectuer la correction et fusionner les fichiers avant de passer au polissage.

Warning :

- Les clusters générés ne sont pas représentatifs de l'ensemble des données, car l'étape de clusterisation est réalisée sur des fichiers séparés.

Problème :

- Erreur de segmentation lors de la clusterisation.

Solutions tentées :

- Variation de la mémoire et du nombre de CPU alloués pour le job.
- Ajout d'une étape supplémentaire de clusterisation et de correction après concaténation.

Résultat :

- Échec.
-

3ème Test

Méthode :

Comme le premier assemblage a fonctionné sur un jeu de données contenant **200 000 reads**, j'ai créé des sous-ensembles de **200 000 reads** à partir du fichier concaténé.

Warning :

- Les clusters générés ne sont pas représentatifs de l'ensemble des données, car l'étape est réalisée sur des sous-ensembles.

Problème :

- Erreur de segmentation lors de la clusterisation.

Solutions tentées :

- Variation de la mémoire et du nombre de CPU alloués pour le job.
- Réduction de la taille des sous-ensembles à **100 000 reads**.

Résultat :

- Échec (mais certaines étapes de clusterisation ont réussi).

4ème Test**Méthode :**

Augmentation significative des ressources allouées (mémoire et CPU).

Problème :

- Processus tué avec le message d'erreur "**54971 Killed**".

Conclusion

Pourrait potentiellement fonctionner en réduisant encore la taille des jeux de données, mais cela rendrait l'étape de clusterisation inutile car elle ne serait plus représentative de l'ensemble des données.

Pour la suite :

- Essayer de faire un transcriptome avec rnaSPADES en utilisant long reads et short reads

 Compte Rendu Réunion - 10 Janvier 2025**Points à suivre et actions à réaliser :****1. Indicateurs de qualité des assemblages**

- Ajouter des métriques complémentaires pour évaluer la qualité des assemblages :
 - **Taille moyenne des contigs.**
 - **N50** (longueur pour laquelle 50% des bases sont incluses dans des contigs de cette taille ou plus).
 - Comparer ces indicateurs aux données disponibles dans la littérature.

2. Test de RATTLE

- Prévoir une session lundi avec **Greg** pour tester **RATTLE** en local.
- Si **RATTLE** ne fonctionne pas, envisager l'utilisation de **cdHitEst** pour effectuer une clusterisation.

3. Analyses de qualité

- Réaliser les analyses suivantes avec les données issues de la littérature :
 - **BUSCO** : évaluation de la complétude des gènes orthologues.
 - **Bowtie2** : taux d'alignement et qualité des assemblages.

- **Alignement Bowtie2 des données de la littérature sur notre assemblage Trinity :**
 - Vérifier si notre transcriptome peut être une bonne référence.

4. Données d'échantillons avec proies

- Réaliser une analyse **Bowtie2** sur les échantillons contenant des proies.
- Envoyer les résultats à **Rossanna**.

5. Données MinION

- Effectuer une analyse **FastQC** sur les runs MinION pour évaluer la qualité des reads.
- Vérifier et expliquer le passage des fichiers **BAM** à **FASTQ** dans la méthodologie utilisée.
- Supprimer les premiers runs de qualité médiocre du tableau des résultats et comparer les données aux références disponibles dans la littérature.

6. Package Oxford Nanopore

- Explorer les fonctionnalités du dernier package **Oxford Nanopore** :
 - Identifier les ARN présentant des queues **polyA**.

rnaSPADES

L'assemblage rnaSPADES a été réalisé avec les reads R1 et R2 du séquençage illumina, pour le projet Karmit ainsi que les long reads obtenu a partir des séquençage minION.

	Assemblage 1
Echantillon	Retrait des 2, 5, 8, 13, 14 et 18
Date	10 Janvier 2025
Version de rnaSPADES	4.0.0
Nombre de transcrits	638 297
Longueur maximum	1 279 086
Longueur minimal	80
Longueur moyenne (N50)	716
GC%	50

BUSCO

Statistique	Pourcentage	Nombre de BUSCOs
BUSCOs complets (C)	84.3%	215
- BUSCOs complets et en copie unique (S)	49.4%	126
- BUSCOs complets et dupliqués (D)	34.9%	89
BUSCOs fragmentés (F)	10.2%	26
BUSCOs manquants (M)	5.5%	14
Nombre total de groupes BUSCO recherchés	-	255

Bowtie2

Statistique	Pourcentage	Nombre de reads
Total des reads	-	333295073
Reads appariés	100.00%	333295073
- Alignés concordamment 0 fois	23.76%	78642271
- Alignés concordamment exactement 1 fois	41.74%	102974715
- Alignés concordamment plus d'une fois	34.50%	151678087
Alignement concordant 0 fois	-	78642271

Statistique	Pourcentage	Nombre de reads
- Alignées discordamment 1 fois	33.24%	19211385
Paires non alignées concordamment ni discordamment	-	59430886
Mates constituant les paires non alignées	-	118861772
- Alignés 0 fois	45.43%	44249791
- Alignés exactement 1 fois	8.61%	6594469
- Alignés plus d'une fois	45.96%	68017512
Taux d'alignement global	92.79%	-

Proportion de BUSCO complets élevés, meilleur assemblage

Je n'ai pas pu lancer bowtie2 sur rnaSPADES parce que les fasta ne sont pas au bon format (multilignes de 60 bases)

 **Compte Rendu Réunion - 27 Janvier 2025**

Objectifs Principaux

- **Création d'un tableau global**
 - Inclure les statistiques des assemblages suivants :
 - 2x Trinity
 - 1x rnaSPADES
 - Ajouter les métriques de **transRATE**.
 - Regarder le nombre de PolyA
 - Réaliser le comptage du nombre de gènes par transcrit.
- **Analyse Orson sur Sebimer**
 - Explorer et examiner les résultats disponibles dans l'outil **Sebimer** pour Orson.
- **Finalisation de RATTLE**
 - Terminer les étapes en cours pour **RATTLE** et valider les résultats.

Tableau récapitulatif

	Bibliographie	Assemblage Trinity n°1	Assemblage Trinity n°2	Assemblage rnaSPADES	Assemblage rnaBLOOM
Echantillons		Retrait des 2, 5, 8, 13, 14 et 18	Retrait des 2, 5, 8, 13, 14 et 18	Retrait des 2, 5, 8, 13, 14 et 18	-
Date		28 Novembre 2024	01 Janvier 2025	10 Janvier 2025	31 Janvier 2025
Version de l'assembleur		2.8.5	2.15.2	4.0.0	2.0.1
Nombre de transcrits	24 594 061	615 933	639 081	638 297	43 126
Longueur maximum	101	91 707	52 209	1 279 086	119 958
Longueur minimal	101	176	175	80	200
Longueur moyenne (N50)	101	764	783	716	740
GC%	48.00%	48.00%	48.00%	50.00%	47.00%
Bowtie		77.30%	77.20%	92.76%	-
BUSCO	45.50%	93.48%	93.36%	84.3 %	12.20%

 **Compte Rendu de Réunion - 04 Février 2025**

CD-HITest sur les données RNAspade

- Faire varier le pourcentage de similarité et analyser les résultats.
- **Analyse BUSCO**
 - Vérifier si le pourcentage d'alignement diminue.
 - Générer deux courbes :
 -  Nombre de reads vs. pourcentage d'alignement.
 -  Score BUSCO en fonction du nombre de reads.

Reprise de l'assemblage avec RNA-Bloom

- Réaliser un nouvel assemblage en intégrant une phase de polishing avec les short reads.

Analyse des séquences polyA dans les données brutes MinION

- Quantifier le nombre de séquences polyA présentes.
- Tester une étape de correction.
- Relancer un assemblage après correction.

Observations et Résultats

- **Problème de script:** Le script de clusterisation se bloque à partir d'une valeur de similarité inférieure à 90%. Le score BUSCO reste stable (environ 77,2%), mais nous avons encore au moins 400 000 transcrits.

RNA-Bloom avec polishing short reads

- **Résultats:**
 - Nombre de reads : 41 930
 - Score BUSCO : 12,6%

RNA-Bloom sur les long reads

- En faisant varier certains paramètres (k = 55, mode sensitive, erreur et graph), nous avons observé une légère amélioration des résultats :
 - Nombre de reads : 111 421
 - Score BUSCO : 22,7%

Assemblage RNA-Bloom avec uniquement des short reads

- **Résultat:** L'assemblage produit 20 708 537 transcrits, ce qui est beaucoup trop !