

Analyse Prymnesium

Prymnesium est un organisme dont le génome est entièrement séquencé et disponible, ce qui en fait une excellente référence pour valider nos données et nos outils.

Objectif n°1 : 04/03/2025

1. **Alignement des transcrits sur le génome**
La première étape consiste à aligner les transcrits sur le génome de Prymnesium en utilisant des outils tels que STAR ou Minimap2. Ces alignements permettront de vérifier la qualité des données et d'identifier les régions transcrites.
2. **Tri des ARN messagers**
Une fois les transcrits alignés, il sera nécessaire de développer un programme dédié au tri des ARN messagers (ARNm). Ce programme devra :
 - Identifier les transcrits contenant une queue polyA.
 - Séparer les très longs transcrits dépourvus de queue polyA (en définissant une taille seuil spécifique).
 - Classer les autres types de transcrits selon leurs caractéristiques.
3. **Assemblage des transcrits**
Les étapes d'assemblage pourront être abordées dans une phase ultérieure, après le tri des ARNm. Cela permettra de reconstruire les séquences complètes et d'analyser leur structure fonctionnelle.

Compte rendu 20/03

Le mapping

L'objectif était de mapper les transcript rna-seq long reads et short reads sur le génome de référence de prymnésium

	Top hat	Bwa	minimap
Type de reads	Transcriptome	Transcriptome	Transcriptome
Type de référence	Génome	Génome	Génome
Long read / short read	short read	short read	Long read
Référence	/home/datawork-lpba/Prymnesium/PrymneGenomeV1/PrymneGenomeV1.fasta	/home/datawork-lpba/Prymnesium/PrymneGenomeV1/PrymneGenomeV1.fasta	/home/datawork-lpba/PrymneGenomeV1/PrymneGenomeV1.fasta
Reads	- /home/ref-bioinfo/ifremer/phytox/p-parvum-mixotrophie/data/raw-sequence/AA_R1.fastq.gz - /home/ref-bioinfo/ifremer/phytox/p-parvum-mixotrophie/data/raw-sequence/AA_R2.fastq.gz	- /home/ref-bioinfo/ifremer/phytox/p-parvum-mixotrophie/data/raw-sequence/AA_R1.fastq.gz - /home/ref-bioinfo/ifremer/phytox/p-parvum-mixotrophie/data/raw-sequence/AA_R2.fastq.gz	/home1/datawork/ltrou...

Interprétation des résultats de TopHat :

Métrique	Valeur	Description
Total reads (gauche/droite)	42 543 888	Nombre total de lectures d'entrée pour chaque brin (R1 et R2).
Reads mappés (gauche)	28 991 422 (68.1%)	Pourcentage des reads de gauche (R1) alignés sur le génome de référence.
Reads mappés (droite)	27 725 722 (65.2%)	Pourcentage des reads de droite (R2) alignés sur le génome de référence.
Reads avec alignements multiples	~3.9%	Reads qui s'alignent à plusieurs endroits du génome, indiquant potentiellement des répétitions ou des isoformes.
Reads avec >20 alignements	39 889	Reads hautement répétitifs qui s'alignent à plus de 20 endroits.
Taux d'alignement global	66.7%	Pourcentage global des reads (R1 et R2) mappés sur le génome.
Paires de reads alignées	24 152 082	Nombre total de paires de reads correctement alignées.
Alignements multiples dans les paires	3.9%	Paires de reads qui ont plusieurs alignements, indiquant une ambiguïté dans le mapping.
Alignements discordants	0.6%	Paires de reads où l'alignement ne suit pas la distance et l'orientation attendues. Peut indiquer des événements de fusion ou d'inversion.
Taux d'alignement concordant	56.4%	Pourcentage des paires de reads correctement alignées sur le génome avec des distances et orientations attendues.

Analyse rapide :

- **Taux d'alignement modéré (66.7%)** : Ce taux est correct.
- **Alignements multiples (3.9%)** : Un taux faible, ce qui est bon car cela signifie que la plupart des reads ont un alignement unique.
- **Alignements discordants (0.6%)**

Visualisation sur IGV avec :

- Le génome de référence : `/home/datawork-lpba/Prymnesium/PrymneGenomeV1/PrymneGenomeV1.fasta`
 - Les fichiers BAM obtenus après TopHat
 - Les fichiers BAM de Minimap2
- Le mapping de BWA n'a pas été utilisé car il gère les short reads de génome, or ce n'était pas notre cas.

Le script de tri

Pour le tri des ARNm, si 90% des 10 dernières bases étaient des A ou des T, la séquence était considérée comme un ARNm. Si ce n'était pas le cas, on regardait la taille : si elle était supérieure à 10 000, alors c'était une potentielle contamination par de l'ADN. Le reste était placé dans un fichier "Autres" (peut-être des ARN non codants ?).

Après utilisation du script, trois fichiers ont été produits avec ces informations :

ARNm

- Nombre de séquences : 86 861
- Taille minimale : 26
- Taille maximale : 13 072
- N50 : 860

ADN

- Nombre de séquences : 1 042
- Taille minimale : 10 018
- Taille maximale : 1 185 182
- N50 : 135 268

Autres

- Nombre de séquences : 3 792 501
- Taille minimale : 5
- Taille maximale : 9 999
- N50 : 896

Assemblage des transcrits

Voici les premiers résultats d'assemblage RNA-BLOOM :

	rnaBLOOM
Echantillons	RNA-seq MinION
Date	14 mars 2025
Version de l'assembleur	2.0.1
Nombre de transcrits	43 848
Longueur maximum	395463
Longueur minimal	200
Longueur moyenne (N50)	1122
GC%	53%
Bowtie	
BUSCO	20.4%

Objectif n°2 : 20/03/2025

Etape 1 : Création du script d'assemblage

Assemblage de trois nouveaux jeux de données après filtration :

- **ARNm**
- **Potentiels ADN**
- **Potentiels ARN non codants**

Sur ces trois transcriptomes :

1. Analyse de la complétude avec **BUSCO**
2. **Remappage des reads bruts** sur les transcriptomes

Si des **ARN non codants** se mapent sur les ARNm, il pourrait être intéressant de les **incorporer dans un nouvel assemblage**.

Étape 2 : Polissage et validation

Après l'assemblage, un polissage sera effectué avec :

- **Rakoon** ou **Pylone** en utilisant les short reads
- **BUSCO** pour évaluer la qualité
- **Re-polissage** si nécessaire

Étape 3 : Trinity et BUSCO (Pour Karlodinium)

- Réalisation d'un **assemblage avec Trinity** sur les données brutes bibliographiques
- **BUSCO**

Compte rendu n°2

Résumé des résultats rnaBLOOM sur différents jeux de données

	rnaBLOOM	rnaBLOOM	rnaBLOOM
Echantillons	ADN potentiels	ARN non codants potentiels	ARNm potentiels
Date	20 mars 2025	20 mars 2025	20 mars 2025
Version de l'assembleur	2.0.1	2.0.1	2.0.1
Nombre de transcrits	572	39 569	6 396
Longueur maximum	386 968	20 821	8626
Longueur minimal	203	200	200
Longueur moyenne (N50)	4 148	1096	821
GC%	44%	54%	50%
Bowtie			
BUSCO	0%	18.50%	0%

Séparation des reads après nettoyage (Porechop) et tri des ARN :

ARNm :

- **Nombre de séquences** : 70 644
- **Taille minimale** : 13
- **Taille maximale** : 10 023
- **N50** : 837

ADN :

- **Nombre de séquences** : 1 038
- **Taille minimale** : 10 018
- **Taille maximale** : 1 185 182
- **N50** : 137 092

Autres :

- **Nombre de séquences** : 3 797 830
- **Taille minimale** : 1
- **Taille maximale** : 9 999
- **N50** : 881

Résumé des résultats rnaBLOOM sur les données RNA-seq MinION filtrées

	rnaBLOOM	rnaBLOOM	rnaBLOOM	rnaBLOOM
Echantillons	RNA-seq MinION avec adaptateurs filtrés	ADN potentiels	ARN non codants potentiels	ARNm potentiels
Date	24 mars 2025	25 mars 2025	25 mars 2025	25 mars 2025
Nombre de transcrits	41 937	544	38 080	5650
Longueur maximum	288 427	390 938	14 188	9041
Longueur minimal	200	203	200	200
Longueur moyenne (N50)	1123	4121	1100	788
GC%	53.00%	44.00% (dont 34% de G)	54.00%	49.00%
Bowtie	72.02%	1.89%		
BUSCO	18.8%	0%	15.70%	0%

Objectif n°3 : 27/03/2023

Objectif n°3 : 27/03/2023

1. **Faire du polishing** avec les **short reads**.
2. **Trinity** sur les short reads de **Prymnesium**.
3. **RNAspades** pour **Prymnesium** en utilisant les profils **S** et **L**.
4. **Minimap2** de l'assemblage sur le **génom**e de référence + **Gene count** avec **bedtools intersect** :
 - Sur **ARNnc** et sur **ARNnc + ARNm**.
5. **Retenter Rattle**.

Compte rendu n°3 :

Dans cette partie, nous avons utilisé le jeu de données issu du **RNA-seq MinION** qui a été filtré et nettoyé grâce à deux packages :

1. **Porechop** pour retirer les adaptateurs.
2. **FastpLong** pour filtrer les reads selon leur qualité.
Cela a produit un jeu de données de **2 996 902 reads** avec un **N50 de 864** et des reads ayant une qualité entre **30 et 50**.

Assemblage de transcriptome

	RATTLE (par défaut)	rnaSPADEs	Trinity	rnaBLOOM	RATTLE + Spoa
Echantillons	RNA-seq MinION avec adaptateurs filtrés + qualités filtrés	- RNA-seq MinION avec adaptateurs filtrés + qualités filtrés - short reads illumina manip mixotrophie	Short reads illumina manip mixotrophie	RNA-seq MinION avec adaptateurs filtrés + qualités filtrés	RNA-seq MinION avec adaptateurs filtrés + qualités filtrés (Greg)
Date	29 mars 2025	07 Avril 2025	07 Avril 2025	02 Avril 2025	
Nombre de transcrits	8379	590 505	228 113	39 862	29 960
Longueur maximum	8085	48 342	42 715	17 128	7 821
Longueur minimal	253	52	175	200	200
Longueur moyenne (N50)	1597	524	1119	1090	1 187
GC%	57%	54%	56%	55%	59%
Bowtie	56.08%	99.32	98.94%	70.88%	72.37%
BUSCO	9%	94.5	94.9%	16%	27.9%

Sur les transcrits rnaSPADES on a en plus :

- Retiré les isoformes en conservant uniquement les isoformes les plus longues
- Fait une étape de clusterisation

	rnaSPADES sans iso	rnaSPADES sans iso + cluster 0.95
Echantillons	RNA-seq MinION avec adaptateurs filtrés + qualités filtrés	- RNA-seq MinION avec adaptateurs filtrés + qualités filtrés - short reads illumina manip mixotrophie
Date	08 Avril 2025	08 Avril 2025
Nombre de transcrits	547 585	545 316
Longueur maximum	48 342	48 342
Longueur minimal	52	52
Longueur moyenne (N50)	360	359
GC%	52%	52%
Bowtie	91.13%	91.10%
BUSCO	92.1%	92.1%