

Assemblage et caractérisation de transcriptomes de dinoflagellés

Master Bioinformatique



Soutenance du 04 Septembre 2025

Etudiante : Lauryn TROUILLOT


Encadrants : Rossana SUSSARELLU & Grégory CARRIER

Introduction

Présentation du labo

- L'IFREMER

Centre Atlantique



Présentation du labo

- **L'IFREMER**


Centre Atlantique

Unité PHYTOX

Physiologie et toxines des microalgues toxiques et nuisibles

3 axes de recherches :

- Les mécanismes physiologiques et les stratégies trophiques des microalgues
- L'écologie chimique, en particulier le rôle des toxines et autres métabolites dans les interactions biotiques
- L'évaluation des risques actuels et l'émergence de toxicités nouvelles



Présentation du labo

- **L'IFREMER**

Centre Atlantique


Unité PHYTOX

Laboratoire METALG

Laboratoire PHYSALG


Laboratoire GENALG

L'étude des mécanismes moléculaires impliqués dans le succès écologique des microalgues toxiques et nuisibles



Contexte scientifique


Le phytoplancton




Cyanobactéries




Anabaena



Microcystis




Oscillatoria



Contexte scientifique

Les microalgues




- Producteur primaire
- Grande diversité taxonomique
- Large répartition géographique



Contexte scientifique

- Les efflorescences algales nuisibles

Lorsque les conditions sont favorables




Nutriments +++

Contexte scientifique

- **Les efflorescences algales nuisibles**

Lorsque les conditions sont favorables



Nutriments +++



Perturbation de l'équilibre des écosystèmes :

- Mort des poissons
- Mort des crustacés
- Atténuation de la lumière


Impact sur l'Homme :

- Intoxication alimentaire
- Mort
- Perte économique
- Diminution du tourisme

Contexte scientifique

- **Les efflorescences algales nuisibles**

Lorsque les conditions sont favorables



Nutriments +++



Perturbation de l'équilibre des écosystèmes :

- Mort des poissons
- Mort des crustacés
- Atténuation de la lumière

Impact sur l'Homme :


- Intoxication alimentaire
- Mort
- Perte économique
- Diminution du tourisme

Les microalgues impliquées :


- Diatomées
- Haptophytes
- Dinoflagellés

Contexte scientifique

- Les dinoflagellés




- Environ 2 300 espèces
 - Environ 123 espèces toxiques
- Groupe morphologiquement très diversifié
- Capable de s'adapter à des habitats très différents



Mais persistent dans l'environnement et sont capables de former des efflorescences


Contexte scientifique

- Les dinoflagellés



Le génome particulier des dinoflagellés :

- Très grandes tailles :
 - 1,2 à 112 Gb (3,2 Gb pour l'Homme)
 - 0,05 % à 1,8 % de gène codants
- Dépourvu de nucléosome :



Cristal liquide

→ Dinoflagellate Viral Nucleoproteins (DVNPs)

↘ Transcription des filaments d'ADN extrachromosomiques

Si ces caractéristiques commencent à être décrites, les mécanismes moléculaires qui les sous-tendent restent encore méconnus


Contexte scientifique

- Les dinoflagellés



Lingulodinium polyedra

- Responsable de marées rouges
- Provoque des phénomènes de bioluminescence
- Produit de la yessotoxine



Dinophysis acuminata

- Produit des toxines diarrhéiques
- Contamine les coquillages
- Transmission par bioaccumulation



Karlodinium veneficum

- Produit de la karlotoxine
- Responsable de mortalité massive d'organismes aquatiques

Objectif

Production *de novo* les transcriptomes les plus complets possible des trois espèces de dinoflagellés toxiques

1

Validation du pipeline sur une microalgue modèle, *Prymnesium parvum*

2

Application du pipeline aux trois espèces de dinoflagellés

3

Annotation fonctionnelle des transcriptomes


Partie 1 : Production des données

Au laboratoire


Réalisées par mes
encadrants

Extraction des ARN

Long reads



Rétrotranscription





Séquencages



Séquençage MinION

Short reads



Séquençage illumina

Nettoyage des données

- Les séquences brutes contiennent fréquemment des erreurs.
 - Erreurs de séquençages
 - Bases de mauvaise qualité aux extrémités
 - Présence des adaptateurs

Long reads

1. Retrait des amorces avec Porechop
2. Suppression des reads avec FastPlong
 - Si qualité phred inférieur à Q20

Pour *D. acuminata* :

- Retrait des proies par alignement avec Minimap2

Short reads

1. Suppression des reads avec FastP
 - Si qualité phred inférieur à Q15

Nettoyage des données

	<i>K. veneficum</i>		<i>D. acuminata</i>		<i>L. polyedra</i>
	Long reads	Short reads	Long reads	Short reads	Short reads
Nombre reads brutes	11 610 725 (100%)	33 226 425 (100%)	1 069 747 (100%)	21 881 964 (100%)	180 000 000 (100%)
Nettoyage porechop	11 530 486 (99.3%)	-	1 059 169 (99%)	-	-
Nettoyage fastp /fastplong	7 294 106 (62.8%)	31 592 251 (95.1%)	459 045 (42.9%)	18 574 774 (84.9%)	168 813 982 (93.8%)
Sans Téléalax et Mesodinium	-	-	409 698 (38.3%)	-	-

Et les long reads ?



Nettoyage des données

	<i>K. veneficum</i>		<i>D. acuminata</i>		<i>L. polyedra</i>
	Long reads	Short reads	Long reads	Short reads	Short reads
Nombre reads brutes	11 610 725 (100%)	33 226 425 (100%)	1 069 747 (100%)	21 881 964 (100%)	180 000 000 (100%)
Nettoyage porechop	11 530 486 (99.3%)	-	1 059 169 (99%)	-	-
Nettoyage fastp /fastplong	7 294 106 (62.8%)	31 592 251 (95.1%)	459 045 (42.9%)	18 574 774 (84.9%)	168 813 982 (93.8%)
Sans Téléalax et Mesodinium	-	-	409 698 (38.3%)	-	-

Pour les short reads :

- Perte de moins de 15% des reads brutes

Pour les long reads :

- Perte de 30 à 60% des reads brutes
- 4 % des reads provenant de proies pour *D. acuminata*

- Technologie illumina mature par rapport a ONT

- Amélioration au fil de run de long reads

Partie 2 : Validation de la méthode sur *P. parvum*

L'organisme modèle



Prymnesium parvum

Caractéristiques :

- Embranchement des haptophytes
- Impliqué dans les efflorescences d'algues toxiques et nuisibles
- Produit une molécule toxique, la prymnesine
- Disponibilité d'un génome de référence

Son génome :

- Taille
 - 93 Mbp à 107 Mbp
- Annotation du génome :
 - 19 000 à 25 000 protéines identifiées
- Génome composé d'introns
 - Epissage alternatif

Obtention du transcriptome

- Assemblage de novo des données brutes

Outils	Données	Implémenté ?	Raisons
RATTLE	Long reads	Oui	-
rnaSPAdes	Short reads et correction long reads	Oui	-
IDP-denovo	Long reads et short reads	Non	Pas de mise à jour depuis 5 ans.
RNA-Bloom2	Long reads	Oui	-
StringTie2	Long reads et short reads	Non	Difficile à implémenter, peut nécessiter une référence, ne produit pas de fichier de séquence.
isONclust	Long reads	Non	Plus un outil de clustering que d'assemblage.
Trinity	Short reads	Oui	-

- 2 assembleurs **long reads**
 - RATTLE
 - RNA-Bloom
- 2 assembleurs **short reads**
 - Trinity
 - rnaSPAdes (**assemble** les short reads puis **corrige** avec les long reads)

Obtention du transcriptome

- Assemblage de novo des données brutes


Outils	Données	Implémenté ?	Raisons
RATTLE	Long reads	Oui	-
rnaSPAdes	Short reads et correction long reads	Oui	-
IDP-denovo	Long reads et short reads	Non	Pas de mise à jour depuis 5 ans.
RNA-Bloom2	Long reads	Oui	-
StringTie2	Long reads et short reads	Non	Difficile à implémenter, peut nécessiter une référence, ne produit pas de fichier de séquence.
isONclust	Long reads	Non	Plus un outil de clustering que d'assemblage.
Trinity	Short reads	Oui	-



Obtention du transcriptome

- Assemblage de novo des données brutes


Outils	Données	Implémenté ?	Raisons
RATTLE	Long reads	Oui	-
rnaSPAdes	Short reads et correction long reads	Oui	-
IDP-denovo	Long reads et short reads	Non	Pas de mise à jour depuis 5 ans.
RNA-Bloom2	Long reads	Oui	-
StringTie2	Long reads et short reads	Non	Difficile à implémenter, peut nécessiter une référence, ne produit pas de fichier de séquence.
isONclust	Long reads	Non	Plus un outil de clustering que d'assemblage.
Trinity	Short reads	Oui	-



Obtention du transcriptome

- Assemblage de novo des données brutes

Outils	Données	Implémenté ?	Raisons
RATTLE	Long reads	Oui	-
rnaSPAdes	Short reads et correction long reads	Oui	-
IDP-denovo	Long reads et short reads	Non	Pas de mise à jour depuis 5 ans.
RNA-Bloom2	Long reads	Oui	-
StringTie2	Long reads et short reads	Non	Difficile à implémenter, peut nécessiter une référence, ne produit pas de fichier de séquence.
isONclust	Long reads	Non	Plus un outil de clustering que d'assemblage.
Trinity	Short reads	Oui	-




Obtention du transcriptome

- Assemblage de novo des données brutes

Outils	Données	Implémenté ?	Raisons
RATTLE	Long reads	Oui	-
rnaSPAdes	Short reads et correction long reads	Oui	-
IDP-denovo	Long reads et short reads	Non	Pas de mise à jour depuis 5 ans.
RNA-Bloom2	Long reads	Oui	-
StringTie2	Long reads et short reads	Non	Difficile à implémenter, peut nécessiter une référence, ne produit pas de fichier de séquence.
isONclust	Long reads	Non	Plus un outil de clustering que d'assemblage.
Trinity	Short reads	Oui	-

Graphe de De Bruijn




Obtention du transcriptome

- Evaluation de la qualité des assemblages

The logo for BUSCO (Benchmarking Universal Single-Copy Orthologs) is displayed in a stylized, bold, red font with a slight 3D effect.

Évaluation de la complétude du transcriptome.

- Score attendu : > 90% pour des espèces modèles

The logo for Bowtie, a software tool for aligning sequencing reads, is shown in a black, stylized font with a white outline.

Évaluation la couverture de l'assemblage, en alignant les reads bruts sur les transcrits assemblés.

The logo for Nucleotide BLAST is a green rectangular box with a white DNA double helix graphic and the text "Nucleotide BLAST" in white.

Alignement BLAST du transcriptome de novo sur le transcriptome de référence.

- Score attendu : > 90%

Statistiques de bases :

- Nombre de transcrits
- Longueurs min et max
- N50

Obtention du transcriptome

- Assemblage de novo des données brutes

	RNA-Bloom	rnaSPAdes	RATTLE	Trinity
Données utilisées	Long reads	Short reads et long reads	Long reads	Short reads
Nombre de transcrits	26 992	104 341	4 003	94 937
Pourcentage de GC	54,30%	57,13%	55,67%	57,42%
N50	1 293	1 925	1967	1 880
Longueur max	13 354	40 548	6 203	20 871
Longueur min	200	53	288	191
Score BUSCO	38,00%	98,80%	11,70%	98,30%
Score Bowtie2	59.06 %	98.69 %	38,20%	98,54%
Score BLAST	50,70%	98,50%	17,10%	98,10%
Moyenne des transcrits par gène	2,6	3,5	1,4	4,3

Obtention du transcriptome

- Assemblage de novo des données brutes

	RNA-Bloom	rnaSPAdes	RATTLE	Trinity
Données utilisées	Long reads	Short reads et long reads	Long reads	Short reads
Nombre de transcrits	26 992	104 341	4 003	94 937
Pourcentage de GC	54,30%	57,13%	55,67%	57,42%
N50	1 293	1 925	1967	1 880
Longueur max	13 354	40 548	6 203	20 871
Longueur min	200	53	288	191
Score BUSCO	38,00%	98,80%	11,70%	98,30%
Score Bowtie2	59.06 %	98.69 %	38,20%	98,54%
Score BLAST	50,70%	98,50%	17,10%	98,10%
Moyenne des transcrits par gène	2,6	3,5	1,4	4,3

Assemblage a partir des long reads :

- RATTLE
 - Transcriptome incomplet
- RNA-Bloom
 - Meilleur score que RATTLE
 - Transcriptome incomplet



Données brutes
insuffisantes

RNA-Bloom fournit un nombre de transcrits et des scores de qualité supérieurs il a donc été sélectionné comme assembleur des long reads

Obtention du transcriptome

- Assemblage de novo des données brutes

	RNA-Bloom	rnaSPAdes	RATTLE	Trinity
Données utilisées	Long reads	Short reads et long reads	Long reads	Short reads
Nombre de transcrits	26 992	104 341	4 003	94 937
Pourcentage de GC	54,30%	57,13%	55,67%	57,42%
N50	1 293	1 925	1967	1 880
Longueur max	13 354	40 548	6 203	20 871
Longueur min	200	53	288	191
Score BUSCO	38,00%	98,80%	11,70%	98,30%
Score Bowtie2	59.06 %	98.69 %	38,20%	98,54%
Score BLAST	50,70%	98,50%	17,10%	98,10%
Moyenne des transcrits par gène	2,6	3,5	1,4	4,3

Assemblage a partir des short reads :

- Beaucoup trop de transcrits
- De bons scores qualité (BUSCO, Bowtie et BLAST)
 - Mais beaucoup de transcrits dupliqués (> 80%)

L'utilisation des graphes de De Bruijn tend à générer de nombreuses séquences très similaires.



L'intégration des long reads avec rnaSPAdes permet d'obtenir une valeur de N50 supérieure à celle de Trinity, reflétant une meilleure continuité des transcrits.

Obtention du transcriptome

- Construction du transcriptome consensus

Hypothèses :


- Utilisation de random hexamere
 - Tous types d'ARN



Hypothèses :

- Librairies PolyA
 - Principalement des ARNm

EvidentialGene



Hypothèses :

- Réduction de la redondance
- Tous types d'ARN

Obtention du transcriptome

- Validation du transcriptome consensus

	EvidentialGene	EvidentialGene + CD-HIT-EST 95
Données utilisées	Assemblage RNA-Bloom et rnaSPAdes	Transcriptome consensus
Nombre de transcrits	66 146	61 553
Pourcentage de GC	57,74%	57,67%
N50	2 011	1 991
Longueur max	40 548	40 548
Longueur min	131	131
Score BUSCO	98,80%	98,80%
Score Bowtie2	97,79%	97,76%
Score BLAST	97,70%	97,60%
Moyenne des transcrits par gène	3,3	2,6

Transcriptome consensus:

- Moins de transcrits
- De bons scores qualité (BUSCO, Bowtie et BLAST)
 - Mais toujours beaucoup de transcrits dupliqués (> 80%)

Obtention du transcriptome

- Validation du transcriptome consensus


	EvidentialGene	EvidentialGene + CD-HIT-EST 95
Données utilisées	Assemblage RNA-Bloom et rnaSPAdes	Transcriptome consensus
Nombre de transcrits	66 146	61 553
Pourcentage de GC	57,74%	57,67%
N50	2 011	1 991
Longueur max	40 548	40 548
Longueur min	131	131
Score BUSCO	98,80%	98,80%
Score Bowtie2	97,79%	97,76%
Score BLAST	97,70%	97,60%
Moyenne des transcrits par gène	3,3	2,6

Transcriptome consensus:

- Moins de transcrits
- De bons scores qualité (BUSCO, Bowtie et BLAST)
 - Mais toujours beaucoup de transcrits dupliqués (> 80%)


EvidentialGene suivi d'un clustering avec CD-HIT-EST, apparaît comme une approche pertinente pour combiner les forces de RNA-Bloom et de rnaSPAdes, tout en réduisant fortement le nombre de transcrits générés par rnaSPAdes

Le pipeline final



Partie 3 : Application du pipeline aux dinoflagellés

Evaluation des transcriptomes des dinoflagellés




Karlodinium veneficum

	<i>K. veneficum</i>
Nombre d'ARN totaux	121 158
N50	1 652
Longueur max	17 218
Longueur min	196
Score BUSCO (alveolata)	97,10%
Score Bowtie2	93,76%

- Nombre de transcrits cohérents
- Scores qualité très bons (BUSCO, Bowtie2)
 - Avec peu de transcrits dupliqués

Le transcriptome produit sans référence pour *K. veneficum* est complet et de bonne qualité

Evaluation des transcriptomes des dinoflagellés



Dinophysis acuminata

	Notre transcriptome	Litterature
Nombre d'ARN totaux	86 767	128 844
N50	882	829
Longueur max	8 288	-
Longueur min	196	-
Score BUSCO (eukaryota)	44,7% (80,07% avec alveolata)	41,58%
Score Bowtie2	81,43%	47,20%

- Nombre de transcrits inférieurs
- N50 supérieure
- Scores qualité meilleures (BUSCO, Bowtie2)
 - Avec peu de transcrits dupliqués

Le transcriptome que nous présentons est donc constitué de moins de transcrits redondants, et un peu mieux que celui présent dans la littérature

Evaluation des transcriptomes des dinoflagellés



Lingulodinium polyedra

	Notre transcriptome	Littérature
Nombre d'ARN totaux	101 926	143 704
N50	1 793	1386
Longueur max	15 763	-
Longueur min	196	-
Score BUSCO (eukaryota)	74,90% (95,9% avec alveolata)	81,85%
Score Bowtie2	95,73%	92,60%

- Nombre de transcrits inférieurs
- N50 supérieure
- Scores qualités moins bons (BUSCO, Bowtie2)
 - Avec peu de transcrits dupliqués

Le transcriptome que nous présentons est donc constitué de moins de transcrits. Le score de complétude est moins bons. La présence de long reads aurait potentiellement permis d'améliorer ces résultats


Partie 4 : Annotation fonctionnelle des transcriptomes

L'annotation fonctionnelle

Etape complémentaire pour **évaluer la qualité** des transcriptomes produits. Elle permet d'observer la **richesse biologique** du jeu de données en vérifiant que les transcrits obtenus couvrent une diversité suffisante de **fonctions cellulaires et métaboliques**



Orson (prOteome and tRanScriptome functiOnal aNnotation)




- Résultats équivalents dans la littérature
 - 28% pour *Alexandrium minutum*
 - 24 % pour *Oxyrrhis marina*

L'annotation reste un défi majeur pour l'étude des transcriptomes, en particulier chez les organismes non modèles

L'annotation fonctionnelle

- La richesse biologique des transcriptomes



Les diverses fonctions attendues pour la survie de l'espèce sont observées

Conclusion et perspectives



Production *de novo* les transcriptomes les plus complets possible des trois espèces de dinoflagellés toxiques

Conclusion :

- Production de transcriptomes de **bonne qualité** pour les 3 espèces de dinoflagellés
- Identification de la **fonction** de seulement **30%** des transcrits
 - Annotation = **défi majeur** de l'analyse de transcriptome

Perspectives

- Le SEBIMER souhaite utiliser des approches basées sur la **structure des protéines** afin d'améliorer l'identification des **fonctions**
- La disponibilité d'un **génom de référence** permettrait de **compléter** les résultats
 - Projets tels que **Atlasea**
- Les transcriptomes produits pourront servir à **l'annotation structurale** des génomes
- Dans le futur, appliquer le pipeline pour fournir de **nouvelles informations** grâce à **l'enrichissement** progressif des bases de données

Merci de votre attention

Filtration des ARN

Pour évaluer la **diversité de d'ARN** dans les transcriptomes :

- Trinity
- rnaSPAdes
- RNA-Bloom
- EvidentialGene + CD-HIT-EST 95%

