

Master Bioinformatique

Nantes Université

Année universitaire 2024 – 2025

Mémoire d'alternance



Assemblage et caractérisation de transcriptomes de dinoflagellés

Lauryn Trouillot

Organisme d'accueil : *Institut Français de Recherche pour l'Exploitation de la Mer (Ifremer), Centre Atlantique*

Encadrants :

- **Grégory Carrier**, Chercheur
- **Rossana Sussarellu**, Chercheuse

Alternance du 09/09/2024 au 05/09/2025

Remerciements

Tout d'abord, je tiens à remercier chaleureusement mes encadrants d'alternance, Rossana Sussarellu et Gregory Carrier, chercheurs à l'Ifremer, Centre Atlantique. Je leur suis profondément reconnaissante pour leur accueil chaleureux, le temps que nous avons passé ensemble et leur volonté de partager leur expertise et leurs connaissances. Leur disponibilité et leur confiance m'ont permis d'accomplir pleinement mes missions.

Je tiens également à exprimer ma gratitude aux stagiaires, doctorants, post-doctorants et alternants qui ont grandement contribué à ce que je me sente à l'aise : Florian, Anaëlle, Morgane, Marinna, Tom, Lou et Loïc, mais également Marie et Quentin.

Je remercie l'ensemble des personnes de l'Ifremer qui ont contribué à mon intégration, en particulier Léna, Élise, Clarisse, Simon, Laurine et bien d'autres.

Je remercie tout particulièrement Simon Taudière pour son soutien indéfectible tout au long du projet.

Enfin, je tiens à remercier toutes les personnes qui m'ont guidée et ont relu mon rapport d'alternance. Leurs conseils, leurs suggestions et leurs commentaires ont grandement contribué à la réalisation de cette étude, et je leur en suis extrêmement reconnaissante.

Table des matières

1. Présentation de l'IFREMER.....	6
2. Contexte scientifique.....	6
2.1. Les dinoflagellés.....	7
2.1.1. Les trois espèces de dinoflagellé d'études	9
2.2. Objectifs du projet.....	10
3. Production des données.....	11
3.1. Acquisition des données au laboratoire	11
3.1.1. L'extraction des ARN	11
3.1.2. La rétrotranscription	11
3.1.3. Le séquençage.....	11
3.2. Prétraitement et nettoyage des données de séquençage.....	12
4. Construction et validation de la méthode d'assemblage sur l'espèce témoin <i>P. Parvum</i>	14
4.1. Assemblages des données brutes de séquençage.....	14
4.2. Mesure de la qualité d'un transcriptome	17
4.3. Comparaison des assemblages obtenus	17
4.3.1. Évaluation des outils pour les long reads	18
4.3.2. Évaluation des outils pour les short reads.....	19
4.4. Construction du transcriptome consensus	19
4.4.1. Première étape.....	19
4.4.2. Deuxième étape	20
4.4.3. Évaluation de l'outil EvidentialGene.....	21
4.4.4. Évaluation de l'outil CD-HIT-EST.....	21
4.4.5. Origine des données dans le transcriptome consensus	22
4.5. Filtration et classification des ARN.....	22
4.5.1. Séparation des ARN codants et non codants	22
4.5.2. Identification des ARN ribosomaux.....	23
4.5.3. Identification des ARN de transferts.....	23
4.5.4. Évaluation de la distribution des ARN à travers les différents transcriptomes assemblées	23
5. Application du pipeline aux dinoflagellés	25

5.1.	Mise en place du pipeline en production.....	25
5.2.	Origine des ARNs dans les transcriptomes	27
6.	Annotation fonctionnelles des transcriptomes.....	27
6.1.	Annotation fonctionnelle du transcriptome	27
7.	Conclusion et perspectives	29
	Bibliographies	31
	Annexes	34

Liste de définitions

Autotrophie : Capacité d'un organisme à produire sa propre matière organique à partir de substances minérales et d'une source d'énergie (ex. lumière pour les organismes photo-synthétiques).

Biotique : Les facteurs biotiques représentent l'ensemble des interactions du vivant sur le vivant dans un écosystème (ex : la prédation).

Endosymbionte : Organisme vivant en symbiose à l'intérieur d'un autre organisme hôte.

HAB (Harmful Algal Bloom) : Prolifération massive d'algues marines pouvant avoir des effets toxiques ou nuisibles sur l'environnement, la faune et la santé humaine.

Haptophyte : Groupe de microalgues eucaryotes marines, généralement unicellulaires, caractérisées par la présence d'un haptonème (appendice cellulaire particulier).

Hétérotrophie : Mode de nutrition consistant à utiliser de la matière organique préexistante comme source de carbone et d'énergie.

Homologue : Séquence ou gène issu d'un ancêtre commun, présentant une similarité avec une autre séquence par la descendance évolutive.

Ichtyotoxique : Se dit d'une substance ou d'une molécule toxique pour les poissons.

Short reads : Séquences courtes d'ADN ou d'ARN produites par des technologies de séquençage à haut débit (ex. Illumina), généralement de 50 à 300 paires de bases.

Long reads : Séquences longues d'ADN ou d'ARN produites par des technologies de séquençage de 3^e génération (ex. PacBio, Oxford Nanopore), pouvant dépasser plusieurs dizaines de kilobases.

Néritique : Zone marine côtière, généralement au-dessus du plateau continental, caractérisée par des eaux peu profondes et riches en nutriments.

ORF (Open Reading Frame) : Portion continue d'ARNm lisible par le ribosome, traduite en chaîne polypeptidique jusqu'à ce qu'un codon stop soit rencontré. En d'autres termes, il s'agit de la séquence traduisible en protéine.

Random Hexamère : Amorces constituées de séquences aléatoires de six nucléotides, utilisées pour initier la transcription inverse lors de la synthèse d'ADNc.

Trophique : Relatif à la nutrition et aux relations alimentaires entre les organismes d'un écosystème (ex. niveaux trophiques).

1. Présentation de l'IFREMER

Créé en 1984, l'Ifremer (Institut Français de Recherche pour l'Exploitation de la Mer) est un organisme public de recherche dédié à la production de connaissances sur le milieu marin. L'institut regroupe 24 unités de recherche qui ont pour objectif de comprendre, le fonctionnement des océans, de gérer durablement les ressources marines, et de développer des technologies innovantes pour l'exploration et la surveillance du milieu marin. L'Ifremer est implanté sur l'ensemble du littoral français, y compris en outre-mer.

Dans le cadre de mon alternance, j'ai intégré le centre Ifremer Atlantique à Nantes, qui regroupe différentes unités travaillant sur la caractérisation et l'évolution des écosystèmes marins. C'est au centre Atlantique que s'organisent et se déploient les réseaux de surveillance des écosystèmes marins. Le REPHY est un réseau qui inventorie la présence des espèces de phytoplancton toxiques, tandis que REPHYTOX surveille les phycotoxines dans les zones côtières françaises. On y trouve également l'étude des sources de contamination microbiologique avec le réseau de surveillance REMI. Des unités de recherche mènent également des activités liées aux polluants chimiques dans le milieu marin et à la surveillance de l'état des populations de poissons. Enfin, plusieurs unités mènent des recherches fondamentales sur la biologie des organismes marins et leur évolution dans le contexte du changement climatique, notamment sur les microalgues toxiques.

Pendant un an, j'ai travaillé au sein de l'unité de recherche PHYTOX (Physiologie et toxines des microalgues toxiques et nuisibles <https://phytox.ifremer.fr/>). Cette unité s'intéresse aux microalgues toxiques et nuisibles autour de trois axes de recherche :

- Les mécanismes physiologiques et les stratégies trophiques des microalgues,
- L'écologie chimique, en particulier le rôle des toxines et autres métabolites dans les interactions biotiques,
- L'évaluation des risques actuels et l'émergence de toxicités nouvelles.

L'unité PHYTOX est organisée en trois laboratoires : METALG, qui étudie les métabolites produits par les microalgues, PHYSALG, qui travaille sur la caractérisation des réponses physiologiques des microalgues toxiques et nuisibles face à leur environnement, et enfin le laboratoire GENALG, que j'ai intégré, dont l'objectif est de comprendre les mécanismes moléculaires impliqués dans le succès écologique des microalgues toxiques et nuisibles.

2. Contexte scientifique

Mon projet d'alternance s'inscrit dans le cadre du programme de recherche PEPR Atlasea, qui a pour ambition de séquencer les génomes de 4 500 espèces marines eucaryotes, incluant des mollusques, crustacés, annélides, cnidaires, ascidies, algues unicel-

lulaires et pluricellulaires, éponges et poissons. Ce programme couvre environ un tiers des espèces marines connues de la métropole et des territoires ultramarins français.

Parmi les organismes ciblés par ce programme figure le phytoplancton, des organismes photosynthétiques unicellulaires aquatiques. Il se compose de deux groupes principaux d'organismes : les cyanobactéries, et les microalgues. Les microalgues regroupent des micro-organismes photosynthétiques appartenant aux règnes des eucaryotes. Ces dernières présentent une grande diversité phylogénétique, étant réparties dans plusieurs taxons (ex. diatomées, dinoflagellés, haptophytes). Les expéditions Tara Oceans ont mis en évidence la diversité des microalgues. L'analyse des séquences d'ADN ribosomique 18s issues de fractions de plancton allant des plus petits eucaryotes unicellulaires jusqu'à de petits animaux de quelques millimètres a révélé près de 150 000 unités taxonomiques opérationnelles (OTUs) (de Vargas et al., 2015). Le phytoplancton présente une immense biodiversité et une large répartition géographique, colonisant divers milieux aquatiques tels que les rivières, les lacs et les océans. Dans ces écosystèmes, il joue un rôle fondamental en tant que producteur primaire, le premier maillon de la chaîne alimentaire, pour les organismes marins. Au printemps et en été, lorsque les conditions environnementales sont favorables (température, lumière, nutriments), certaines espèces de phytoplancton peuvent proliférer rapidement et former des efflorescences, également appelées « blooms », pour la plupart sans conséquence. Cependant, ces phénomènes naturels peuvent parfois devenir nuisibles. Certaines proliférations de microalgues, engendrent des efflorescences algales nuisibles ou toxiques (Harmful Algal Blooms, ou HABs), qui perturbent l'équilibre écologiques des écosystèmes. Elles peuvent entraîner la mort de poissons ou de crustacés, notamment par la production de toxines. L'accumulation massive de leur biomasse peut également provoquer une atténuation de la lumière, un colmatage des branchies ou encore un épuisement de l'oxygène dissous. Chez l'être humain, les toxines produites par les HABs peuvent provoquer divers syndromes allant d'une simple intoxication alimentaire à la mort pour les plus dangereuses ([saxitoxine](#)). Enfin, d'un point de vue économique, ces proliférations engendrent chaque année des pertes de plusieurs millions de dollars pour l'économie américaine, notamment en raison de la diminution du tourisme, de la baisse des rendements en aquaculture et de l'impact sur la pêche (<https://hab.who.edu/about>). Plusieurs familles de microalgues sont impliquées dans ces proliférations, notamment les diatomées et mais surtout les dinoflagellés, le groupe comportant le plus d'espèces toxiques (Beedessee et al., 2020).

2.1. Les dinoflagellés

Dans le cadre de mon alternance, nous nous sommes focalisés sur les dinoflagellés qui provoquent des blooms toxiques aux conséquences écologiques et économiques sur les côtes françaises.

Les dinoflagellés sont un taxon comptant plus de 2 300 espèces, dont 60 espèces connues pour produire des toxines. C'est un groupe morphologiquement très diversifié dont les espèces s'adaptent à des habitats très différents : petits étangs, rivières, lacs, estuaires, océans, et ce, de l'Antarctique à l'Arctique. Les dinoflagellés présentent divers modes de nutrition (autotrophe, hétérotrophe, mixotrophe) et des interactions avec d'autres espèces, allant du parasitisme au mutualisme. Par exemple la lignée Symbiodiniaceae est devenue un endosymbionte indispensable des coraux (Lin, 2024).

Ces organismes unicellulaires ont une biologie très particulière en comparaison à d'autres taxons, notamment concernant leur cycle de vie. Les dinoflagellés croissent très lentement comparés aux espèces des autres taxons (diatomées, haptophytes etc.) (Muthinda et al., 2016), mais paradoxalement, persistent dans l'environnement et sont capables de former des efflorescences. De plus, l'étude de leur génome constitue un véritable défi en raison de sa taille et de son organisation particulières (Verma et al., 2019).

Le génome de la plupart des dinoflagellés est très grand pour un organisme unicellulaire eucaryote, avec une taille variant de 1,2 à 112 Gb (Verma et al., 2019). L'une de ses particularités réside dans sa structure : il est dépourvu de nucléosomes, mais les chromosomes resteraient dans un état dit de « cristal liquide ». Il semblerait que cet état soit assuré par des protéines d'origine virale, les Dinoflagellate Viral Nucleoproteins (DVNPs). Cette organisation influence directement les mécanismes de transcription, qui s'effectueraient sur des filaments d'ADN extrachromosomique (Roy & Morse, 2013). Si ces caractéristiques commencent à être décrites, les mécanismes moléculaires qui les sous-tendent restent encore méconnus. La compréhension de cette organisation génomique et de son influence sur la régulation de l'expression des gènes constitue donc un champ d'étude encore largement ouvert.

En ce qui concerne sa composition, l'ADN des dinoflagellés présente une teneur relativement élevée en guanine et cytosine, comprise entre 45 et 70 %, et est fortement méthylé grâce à des bases modifiées telles que la 5-hydroxyméthyluracile, et en moindre partie la 5-méthylcytosine et la N⁶-méthyladénine (Verma et al., 2019). La proportion codante dans le génome des dinoflagellés reste inférieure à ce que l'on pourrait attendre, avec un nombre de gènes codant pour des protéines variant de 37 000 à 87 000, ce qui ne représente que 0,05 % à 1,8 % du génome total (Verma et al., 2019). À l'inverse, il a été observé que près de 20 % des gènes séquencés chez ces espèces sont partiellement ou totalement dépourvus d'introns (Verma et al., 2019). Ces gènes, dépourvus d'introns, seraient issus d'ADN complémentaire et proviendraient notamment de cyanobactéries, d'algues rouges, d'haptophytes et même de bactéries. Ils auraient été acquis par transfert horizontal et seraient intégrés aux génomes des dinoflagellés en l'état sans passer par un processus de domestication. À ce jour, leur fonctionnalité reste inconnue.

Enfin chez les dinoflagellés, la régulation de l'expression des gènes diffère des autres eucaryotes. Alors que de nombreux eucaryotes contrôlent l'expression génique

à l'aide de promoteurs bien définis (comme les séquences TATA-box, CAAT-box ou GC-box) et de facteurs de transcription spécifiques, ces éléments sont rarement identifiables dans les séquences génomiques des dinoflagellés (Roy & Morse, 2013).

2.1.1. Les trois espèces de dinoflagellé d'études

Comme exposé précédemment, les dinoflagellés sont des organismes atypiques, que ce soit par leur capacité à persister dans des habitats très variés, ou encore leur génome complexe. Pourtant, malgré leur importance écologique et leur impact économique et sur les écosystèmes, ces microalgues restent encore très peu étudiées. Leur étude s'avère indispensable, mais elle se heurte à la complexité même de ces organismes. Dans le cadre de mon alternance, je me focaliserai sur trois espèces de dinoflagellés toxiques, capables d'induire des HABs et présentent dans les régions Bretagne et Pays de la Loire : *Lingulodinium polyedra*, *Dinophysis acuminata* et *Karlodinium veneficum*.




Figure 1 : Photo au microscope électronique à balayage de *Lingulodinium polyedra* (a) , *Karlodinium veneficum* (b) et *Dinophysis acuminata* (c).

Lingulodinium polyedra (Figure 1a) est un dinoflagellé photosynthétique mobile, connue pour être responsable de marées rouges ainsi que de phénomènes de bioluminescence nocturne. Cette espèce est largement répandue dans les eaux côtières tempérées à subtropicales, avec des signalements dans l'océan Atlantique (mer des Caraïbes, côte est des États-Unis, côte ouest de l'Afrique, côte ouest du Royaume-Uni, au large des estuaires de la Vilaine et de la Loire) et dans l'océan Pacifique (notamment le long de la côte ouest des États-Unis). *L. polyedra* est connue pour produire une toxine appelée yessotoxine. Ces molécules peuvent s'accumuler dans les mollusques bivalves et sont suspectées de provoquer des effets neurotoxiques ou paralytiques chez les organismes marins (Barbosa et al., 2024). La nature et l'impact de ces toxines n'est pas encore entièrement élucidée, en particulier chez l'homme.

Karlodinium veneficum (Figure 1b) est une espèce de dinoflagellé fréquemment associée à de nombreuses efflorescences algales toxiques dans le monde entier. Elle est

particulièrement problématique en raison de sa capacité à produire une ichtyotoxine, appelée karlotoxine, présentant des effets hémolytiques, ichtyotoxiques (toxiques pour les poissons) et cytotoxiques. Cette toxine est responsable de mortalités massives d'organismes aquatiques, en particulier de poissons, lors de blooms (Wang et al., 2020).

Enfin, *Dinophysis acuminata* (Figure 1c) est une espèce particulièrement surveillée dans le cadre des programmes de santé publique. Elle est largement répartie dans les eaux tropicales, tempérées et boréales, et se rencontre aussi bien dans les zones côtières que dans les environnements néritiques et océaniques. Ce dinoflagellé est capable de produire des toxines diarrhéiques, qui peuvent contaminer les coquillages filtrants. Par bioaccumulation, ces toxines peuvent être transmises à l'humain via la consommation de coquillages contaminés, provoquant des gastro-entérites aiguës. Les blooms de *D. acuminata* ont ainsi des impacts sanitaires et économiques significatifs : ils peuvent entraîner la fermeture temporaire de plages, l'interdiction de la commercialisation de coquillages et des restrictions sur les activités de pêche dans les zones affectées (Reguera et al., 2024).

2.2. Objectifs du projet

Compte tenu de l'influence des dinoflagellés sur les écosystèmes marins ainsi que sur certaines activités humaines, il est important de mieux comprendre leur biologie, notamment l'impact des conditions environnementales favorisant leur prolifération. En l'absence de génomes de références pour ces microalgues, l'obtention de transcriptomes de référence s'avère pertinente pour déterminer quels gènes sont exprimés, à quel moment et dans quelles conditions, constituant ainsi une étape clé pour établir des liens entre le génotype et le phénotype.

L'objectif principal de mon projet d'alternance est de produire *de novo* les transcriptomes les plus complets possible des trois espèces de dinoflagellés toxiques : *Lingulodinium polyedra*, *Dinophysis acuminata* et *Karlodinium veneficum*. Bien que connues pour leurs efflorescences nuisibles, ces espèces ne disposent actuellement d'aucun génome ou transcriptome de référence. Pour atteindre cet objectif, une première étape consiste à construire le pipeline sur une microalgue modèle, *Prymnesium parvum* qui est moins complexe, et pour laquelle un génome de référence existe. Le pipeline, une fois validé, sera ensuite appliqué aux trois espèces de dinoflagellés. Enfin, une première annotation fonctionnelle sera réalisée sur les transcriptomes de référence produits.

3. Production des données

Pour pallier la structure génomique particulière des dinoflagellés et permettre la reconstruction de transcrits les plus complets possibles, deux préparations d'ARN ont été effectuées. Deux technologies de séquençage complémentaires ont ensuite été mises en œuvre : les long reads via ONT et les short reads via Illumina. Les long reads permettent d'obtenir un nombre plus limité de transcrits, mais de pleine longueur, tandis que les short reads produisent un volume de données plus important mais fragmenté. L'association de ces deux approches offre ainsi la possibilité de reconstruire des transcrits complets.

3.1. Acquisition des données au laboratoire

La partie acquisition des données en laboratoire a été réalisée par mes encadrants, mais j'ai eu l'occasion d'assister à une préparation d'ARN et à leur séquençage sur MinION. La connaissance des méthodes d'obtention des données de séquençage est indispensable afin de choisir par la suite les outils adaptés au traitement des données.

3.1.1. L'extraction des ARN

Afin d'obtenir les molécules d'ARNs présents dans les microalgues, une première étape d'extraction est réalisée, cette étape consiste en la lyse des cellules, afin de rendre le matériel génétique accessible. Que ce soit pour les long reads ou les short reads, l'extraction des ARN a été réalisée avec un protocole basé sur le TRIzol, ce réactif permet de séparer la phase aqueuse (contenant l'ARN) de la phase organique (contenant l'ADN et les protéines). Ensuite, pour les long reads, un traitement à la DNase (DNase I) pour éliminer l'ADN génomique a été effectué. Pour les short reads une capture à l'aide de billes magnétiques PolyA permet de ne sélectionner uniquement les ARN messagers.

3.1.2. La rétrotranscription

La rétrotranscription est l'étape permettant de transformer l'ARN en ADN complémentaire. Pour les long reads la rétrotranscription a été réalisée à partir d'amorces random hexamères. Ces amorces permettent de capturer, en théorie toute, la diversité des ARN (messagers, ribosomiques, de transfert, etc.), ce qui est particulièrement pertinent chez les dinoflagellés, dont les mécanismes de transcription restent encore peu caractérisés. Pour les short reads, la rétrotranscription est réalisée à partir des amorces poly(T), favorisant donc le séquençage de la partie 3' des ARNs.

3.1.3. Le séquençage

Les long reads brutes ont ensuite été générées à l'aide d'un séquenceur MinION (Oxford Nanopore Technologies) au sein du laboratoire. A cause de soucis de culture les long reads n'ont pas été obtenus pour *L. polyedra* (voir Tableau 1 ci-dessous). Pour les short reads les banques ont été séquencées à l'aide d'un séquenceur Illumina NovaSeq

via une plateforme d'analyse, en paired-end 100pb. Les données short reads ont été produites par le laboratoire à l'exception de *Dinophysis*, pour lequel les données publiques produites par d'autres équipes l'Ifremer ont été utilisées.

Tableau 1 : Tableau résumé de l'origine des données.

	<i>Prymnesium parvum</i>	<i>Lingulodinium polyedra</i>	<i>Karlodinium veneficum</i>	<i>Dinophysis acuminata</i>
Nom de la souche	RCC3707	IFR	IFR-CC-20-44	IFR-DAU-01EY
Origine des long reads	Production en interne	-	Production en interne	Production en interne
Origine des short reads	Production en interne	Production en interne	Production en interne	Données publiques (SRA ERR9832999)

3.2. Prétraitement et nettoyage des données de séquençage

Les séquences brutes contiennent fréquemment des erreurs, telles que des erreurs de séquençage, des bases de mauvaise qualité aux extrémités, ou encore la présence de séquences issues des d'adaptateurs pour le séquençage. L'utilisation de données non nettoyées peut introduire des biais lors de l'assemblage, c'est pourquoi des étapes de filtration sont nécessaires pour ne conserver que des séquences de bonne qualité et sans adaptateurs.

Pour les short reads, la suppression des adaptateurs et des lectures de mauvaise qualité a été réalisée à l'aide de l'outil FastP (Chen, 2023) Seuls les reads présentant une qualité supérieure à Q15 et dépourvus d'adaptateurs ont été conservés. Pour les long reads, une première étape de retrait des amorces a été effectuée à l'aide de Porechop (Wick, 2017/2025), suivie d'une étape de filtration avec FastPlong (Chen, 2023), avec un seuil de qualité fixé à Q20. Cette filtration en 2 étapes évite le retrait d'un trop grand nombre de reads dû à la présence d'amorces, car bien que Fastplong détecte les amorces il ne les retire pas mais supprime directement toute la séquence concernée.

Tableau 2 : Tableau résumé du nombre de reads après les différentes étapes de nettoyage.

	<i>P. parvum</i>		<i>K. veneficum</i>		<i>D. acuminata</i>		<i>L. polyedra</i>
	Long reads	Short reads	Long reads	Short reads	Long reads	Short reads	Short reads
Nombre reads brutes	3 880 404 (100%)	42 543 888 (100%)	11 610 725 (100%)	33 226 425 (100%)	1 069 747 (100%)	21 881 964 (100%)	180 000 000 (100%)
Nettoyage porechop	2 996 902 (77.2%)	-	11 530 486 (99.3%)	-	1 059 169 (99%)	-	-
Nettoyage fastp /fast-plong	2 996 902 (77.2%)	40 658 949 (95.6%)	7 294 106 (62.8%)	31 592 251 (95.1%)	459 045 (42.9%)	18 574 774 (84.9%)	168 813 982 (93.8%)
Sans Téléaulax et Mesodinium	-	-	-	-	409 698 (38.3%)	-	-

La sélection des reads de bonne qualité a entraîné la suppression de moins de 15% des short reads bruts pour chaque espèce. Cette perte limitée est cohérente avec la maturité de la technologie Illumina, développée dans les années 2000. En revanche, les protocoles et la technologie Oxford Nanopore sont plus récents et encore peu maîtrisés, en particulier pour des espèces non modèles. Ainsi, le premier run réalisé sur le dinoflagellé *D. acuminata* présentait une qualité inférieure, entraînant une forte suppression de reads. Au fil des séquençages, une meilleure expertise du protocole a été acquise, ce qui a permis une amélioration notable de la qualité, passant de 57% de reads supprimés à 33%.

Pour *D. acuminata*, une étape de filtration supplémentaire a été réalisée. En effet, sa culture nécessite la présence de les proies *Mesodinium rubrum* et *Teleaulax amphioxea*. Afin d'obtenir uniquement le transcriptome de *D. acuminata*, la culture a été maintenue une semaine en restriction alimentaire. Ensuite en complément des étapes de nettoyage, une filtration des reads issus des proies a été effectuée à l'aide de Minimap2 (H. Li, 2018). Le retrait de ces reads a entraîné une perte d'environ 4 % des données nettoyées.

4. Construction et validation de la méthode d'assemblage sur l'espèce témoin *P. Parvum*

Afin de valider la méthodologie bioinformatique, un organisme témoin, *Prymnesium parvum* (Figure 2) a été sélectionné, il s'agit d'une microalgue appartenant à l'embranchement des haptophytes. Cette espèce est également impliquée dans des efflorescences toxiques, et produit des toxines hémolytiques, cytotoxiques et ichtyotoxiques. Elle a été choisie en raison de son intérêt et de la disponibilité d'une annotation des gènes à partir d'un génome de référence de bonne qualité (Jian et al., 2024). Le génome de plusieurs souches de *P. parvum* ont été assemblés et étudiés. Les taille de génome varient entre 93 Mbp et 107 Mbp avec une estimation de 19 000 à 25 000 gènes codants pour des protéines (Jian et al., 2024). Cette microalgue est un organisme unicellulaire complexe, présentant en moyenne 4,7 exons par gène, soit environ 3 à 4 introns par gène. Cette richesse en introns suggère un potentiel d'épissage alternatif qui peut augmenter le nombre total de transcrits attendus dans le transcriptome.



Figure 2 : Photo au microscope optique de *Prymnesium parvum*.

L'objectif est de construire et valider un pipeline à partir de données de séquençage short read et long reads permettant d'obtenir un assemblage d'un transcriptome de qualité, de l'espèce témoin *P. parvum*. Ainsi, le transcriptome produit dans cette étude devrait contenir au minimum 19 000 transcrits, correspondant au nombre de gènes codants attendus chez *P. parvum*.

4.1. Assemblages des données brutes de séquençage

Plusieurs assembleurs ont été sélectionnés afin d'être testés sur l'espèce de référence. Leur choix s'est basé sur différents critères : leur maintien actif et leur popularité au sein de la communauté scientifique, leur compatibilité avec les données long reads, ainsi que leur capacité à réaliser un assemblage *de novo*.

Après avoir identifié sept assembleurs potentiels (voir tableau 3), quatre ont été implémentés et testés.

Tableau 3 : Résumé des différents assembleurs testés.

Outils	Données	Implémenté ?	Raisons
RATTLE	Long reads	Oui	-
rnaSPAdes	Short reads et correction long reads	Oui	-
IDP-denovo	Long reads et short reads	Non	Pas de mise à jour depuis 5 ans.
RNA-Bloom2	Long reads	Oui	-
StringTie2	Long reads et short reads	Non	Difficile à implémenter, peut nécessiter une référence, ne produit pas de fichier de séquence.
isONclust	Long reads	Non	Plus un outil de clustering que d'assemblage.
Trinity	Short reads	Oui	-

Dans ce rapport, seuls les deux outils conservés dans le pipeline final sont présentés en détail. Il s'agit de RNA-Bloom (Nip, 2017), un assembleur basé exclusivement sur les long reads, ainsi que rnaSPAdes (Prijbelski et al., 2020), qui permet un assemblage hybride combinant long reads et short reads. Ces 2 outils adoptent des algorithmes de graphes, et plus précisément la méthode de De Bruijn. La méthode est la suivante : les reads sont découpés en k-mers ; dans la Figure 3, les k-mers sont composés de 5 paires de bases. Ensuite, un graphe est construit où les nœuds représentent l'ensemble des (k-1)mers (soit 4 pb), et les arêtes relient un nœud à un autre si l'on peut passer de l'un à l'autre par un k-mer. Une fois le graphe construit, l'objectif est de retrouver le chemin qui reconstitue la séquence d'origine, un chemin eulérien est donc recherché, c'est-à-dire le chemin qui passe une seule fois par chaque arête du graphe. C'est un algorithme très performant pour les grands volumes de lectures courtes. Cependant, il est très sensible aux erreurs de séquençage, et produit un grand nombre de transcrits car ces graphes capturent toutes les séquences chevauchantes possibles, y compris celles issues de variations biologiques comme l'épissage alternatif, les erreurs ou les répétitions dans les jeux de données.




Figure 3 : Schéma du principe de graphe du Bruijn pour l'assemblage de génome.

Ces deux outils reposent sur les graphes de De Bruijn, mais les données d'entrée, ainsi que leur manière de les construire et de les exploiter, sont différentes. D'un côté, rnaSPAdes en mode hybride prend en entrée des short reads, qu'il assemble via un graphe de De Bruijn multi-k (plusieurs tailles de k-mer simultanément), puis étend et corrige les transcrits à l'aide des long reads. Ainsi, si un gène est uniquement présent dans les long reads, il sera absent du transcriptome produit par rnaSPAdes. La stratégie d'assemblage de rnaSPAdes est efficace pour la détection des variantes d'épissage et des isoformes, mais au prix d'une forte duplication de séquences.

De l'autre côté, RNA-Bloom utilise uniquement des long reads pour l'assemblage. Cet outil exploite également le graphe de De Bruijn, mais pour économiser de la mémoire, celui-ci est stocké dans une structure probabiliste appelée filtre de Bloom. Du fait de l'utilisation des long reads, la stratégie d'assemblage de RNA-Bloom privilégie la continuité

des transcrits et réduit la fragmentation par rapport aux short reads, cependant la qualité d'assemblage est très dépendante de la qualité et de la quantité des long reads.

4.2. Mesure de la qualité d'un transcriptome

La littérature a mis en évidence que, chez *P. parvum*, 19 000 à 25 000 gènes codants sont présents dans le génome de cette espèce. À l'Ifremer, un transcriptome a été produit à partir de leur propre génome de référence, il est composé de 15 076 transcrits. Afin de valider notre méthode, le transcriptome *de novo* de *P. parvum* doit être constitué d'au moins 19 000 transcrits et couvrir à minima 90 % du transcriptome produit à partir du génome de référence. Le pourcentage de couverture est obtenu avec un alignement BLAST du transcriptome *de novo* sur le transcriptome de référence.

De plus, la qualité des assemblages a été évaluée selon plusieurs critères. Tout d'abord, la complétude a été mesurée à l'aide de l'outil BUSCO (Manni et al., 2021) en utilisant les bases de données alveolata et eukaryota. Les bases de données de l'outil contiennent des gènes BUSCO, c'est-à-dire des gènes orthologues universels retrouvés de manière conservée dans un groupe taxonomique donné. Un bon score BUSCO (supérieur à 90 %) est généralement le signe d'un assemblage complet et de bonne qualité. Le second outil utilisé est Bowtie2 (Langmead & Salzberg, 2012), il permet d'évaluer la couverture de l'assemblage, en alignant les reads bruts sur les transcrits assemblés. Un taux élevé d'alignement témoigne de la présence de l'ensemble des ARN présent dans les données brutes.

4.3. Comparaison des assemblages obtenus

Les données brutes ont été assemblées par 4 outils différents, afin d'identifier le meilleur assembleur selon le type de données. Dans le but de combiner les informations apportées par les long reads et les short reads, les meilleurs transcriptomes pour chacun de ces 2 types de données seront combinés. Le tableau ci-dessous présente les résultats obtenus à partir des différents outils d'assemblages sur *P. parvum*.

Tableau 4 : Tableau résumé des statistiques d'assemblages du transcriptome de *P. parvum*. Le score BLAST est le taux d'alignement du transcriptome *de novo* sur le transcriptome issu du génome.

	RNA-Bloom	rnaSPAdes	RATTLE	Trinity
Données utilisées	Long reads	Short reads et long reads	Long reads	Short reads
Nombre de transcrits	26 992	104 341	4 003	94 937
Pourcentage de GC	54,3 %	57,13 %	55,67 %	57,42 %
N50	1 293	1 925	1967	1 880
Longueur max	13 354	40 548	6 203	20 871
Longueur min	200	53	288	191
Score BUSCO	38,0 %	98,8 %	11,7 %	98,3 %
Score Bowtie2	59,06 %	98,69 %	38,20 %	98,54 %
Score BLAST	50,7%	98,5%	17,1 %	98,1 %
Moyenne des transcrits par gène	2,6	3,5	1,4	4,3

Entre les différents outils le nombre de transcrits varie énormément allant de 4 000 (RATTLE) à 104 000 transcrits (rnaSPAdes) pour la même espèce.

4.3.1.Évaluation des outils pour les long reads

Le transcriptome obtenu avec RATTLE présente un nombre de transcrits insuffisant (4 003 transcrits), ainsi qu'un score de complétude (11,7 %) et un taux d'alignement des reads bruts sur le transcriptome faibles (38 %). Ces résultats indiquent que le transcriptome obtenu avec cette technique est incomplet.

L'assembleur RNA-Bloom produit un nombre de transcrits cohérent avec les valeurs attendues. Cependant, le score de complétude reste faible (38 %), et seulement 59,06 % des reads brutes s'alignent sur le transcriptome généré. Un score d'alignement faible suggère que le transcriptome n'est pas complet ou que l'assembleur n'a pas exploité l'ensemble des reads disponibles. Cela peut résulter d'une diversité trop importante des reads et/ou d'un nombre de reads insuffisant, limitant la reconstruction complète des transcrits. Néanmoins, les transcrits assemblés par RNA-Bloom sont de bonne qualité.

Dans l'ensemble, les deux assembleurs basés sur les long reads présentent un score de complétude bas et une faible représentation des reads dans le transcriptome.

Toutefois, RNA-Bloom fournit un nombre de transcrits et des scores de qualité supérieurs à ceux obtenus avec RATTLE. RNA-Bloom a donc été sélectionné comme assembleur des long reads.

4.3.2. Évaluation des outils pour les short reads

Avec l'assemblage Trinity (exclusivement short reads), un grand nombre de transcrits a été généré (94 937 transcrits). Le score BUSCO de 98,3 % témoigne d'une bonne complétude du transcriptome. Par ailleurs, 98,54 % des reads bruts s'alignent sur le transcriptome, ce qui suggère que peu d'ARN sont manquants.

L'assembleur rnaSPAdes produit également un nombre de transcrits supérieur aux attentes, avec des scores de qualité tout aussi bons. En effet, 98,69 % des données brutes s'alignent sur le transcriptome, et le score BUSCO est de 98,8 %.

Enfin environ 98 % des gènes du transcriptome de référence de *P.parvum* sont retrouvés dans les assemblages Trinity et rnaSPAdes.

L'analyse des résultats BUSCO montre que les deux transcriptomes présentent un taux important de duplications, atteignant 80,1 % pour rnaSPAdes et 82,5 % pour Trinity. Cette proportion élevée est confirmée par le rapport entre le nombre de transcrits et le nombre de gènes du transcriptome de référence : en moyenne, pour un gène, de 3,5 à 4,3 transcrits sont présents dans les assemblages. Ce phénomène peut s'expliquer par l'utilisation des graphes de De Bruijn dans l'algorithme des outils, qui tend à générer de nombreuses séquences très similaires. Cela peut également refléter en partie l'épissage alternatif, conduisant à plusieurs ARNm pour un même gène.

Globalement, les assembleurs de short reads produisent des résultats comparables en termes de qualité et de nombre de transcrits. Toutefois, l'intégration des long reads avec rnaSPAdes permet d'obtenir une valeur de N50 supérieure à celle de Trinity, reflétant une meilleure continuité des transcrits et une reconstruction plus fidèle des ARN de pleine longueur. Ainsi, bien que les deux transcriptomes présentent un nombre de transcrits trop élevé, ceux de rnaSPAdes apparaissent plus complets.

Afin de bénéficier des informations apportées par les deux types de données, long reads et short reads, les transcriptomes considérés comme les meilleurs pour chaque type ont été sélectionnés. Ainsi, RNA-Bloom et rnaSPAdes ont été retenus pour construire un transcriptome consensus.

4.4. Construction du transcriptome consensus

4.4.1. Première étape

Un transcriptome consensus a ensuite été construit dans le but d'améliorer l'exhaustivité du transcriptome et de cumuler les avantages des 2 assemblages précédem-

ment sélectionnées. Cela a été réalisé à l'aide de l'outil EvidentialGene (Nakasugi et al., 2014). Ce logiciel sert à réduire la redondance dans un ou plusieurs assemblages de transcriptomes, afin de sélectionner un jeu de gènes épuré, non redondant et fiable, basé sur le potentiel des séquences codantes. La première étape consiste en l'identification des séquences codantes. Pour cela, les séquences sont traduites en acides aminés et un score de qualité leur est attribué, se basant sur la présence d'un codon start, d'un codon stop et d'une longueur raisonnable. Les meilleures séquences d'acides aminés sont ensuite utilisées pour déterminer la portion du transcrit réellement traduite en protéine (Coding DNA Sequence ou CDS). La seconde étape vise à supprimer la redondance, grâce à la suppression des doublons et des fragments parfaits. Une étape de regroupement des séquences d'acides aminés est ensuite réalisée dans le but de créer des groupes d'isoformes probables. Enfin, pour distinguer les isoformes alternatifs des transcrits redondants, les CDS sont réalignées entre elles au sein du même cluster avec BLASTn, dans l'objectif de voir si certaines sont très proches génétiquement (même exon, même gène) ou liées par une variation alternative.

4.4.2. Deuxième étape

Bien que EvidentialGene applique un processus de déduplication, le transcriptome résultant présentait un niveau de redondance élevé (en particulier plusieurs isoformes), notamment en raison de la complexité biologique de l'espèce. Afin d'obtenir un jeu de transcrits comportant moins d'isoformes, une étape supplémentaire de clustering a été appliquée avec le logiciel cd-hit-est (W. Li & Godzik, 2006), à un seuil de similarité de 95%. Cela a permis de regrouper les transcrits similaires basé sur leur séquence nucléiques (et non protéiques comme dans EvidentialGene) et de ne conserver qu'un représentant par cluster.

Le tableau ci-contre présente les résultats du transcriptomes consensus, et du transcriptome consensus clusterisé.

Tableau 4 : Tableau résumé des statistiques d'assemblages du transcriptome de *P. parvum*.

	EvidentialGene	EvidentialGene + CD-HIT-EST 95
Données utilisées	Assemblage RNA-Bloom et rnS-PADES	Transcriptome consensus
Nombre de transcrits	66 146	61 553
Pourcentage de GC	57,74 %	57,67 %
N50	2 011	1 991
Longueur max	40 548	40 548
Longueur min	131	131
Score BUSCO	98,8 %	98,8 %
Score Bowtie2	97,79 %	97,76%
Score BLAST	97,7 %	97,6%
Moyenne des transcrits par gène	3,3	2,6

4.4.3. Évaluation de l'outil EvidentialGene

L'utilisation d'EvidentialGene avec les transcriptomes produits par RNA-Bloom et rnaSPAdes a permis d'obtenir un transcriptome présentant une réduction du nombre de transcrits. Cette réduction impacte très faiblement les scores de qualité par rapport à l'assemblage produit par rnaSPAdes, avec une représentation des reads dans le transcriptome de 97,79 %, 97,7 % des gènes du transcriptome de référence présents dans l'assemblage *de novo*, et un score de complétude BUSCO de 98,8 %. Ce score comprend 14 % de BUSCOs uniques et 84,8 % de BUSCOs dupliqués. Le taux de duplication reste élevé, tout comme le rapport entre le nombre de transcrits par gène de référence, qui est de 3,3. Au total, 66 146 transcrits ont été conservés (soit 50 % des transcrits issus des assemblages RNA-Bloom et rnaSPAdes), ce qui reste élevé par rapport au transcriptome issu de l'annotation du génome.

4.4.4. Évaluation de l'outil CD-HIT-EST

L'étape de clustering avec CD-HIT-EST a ensuite permis de réduire davantage le nombre de transcrits, sans altérer les scores de qualité. Cependant cette réduction du nombre de transcrit est mineure (-7%).

4.4.5. Origine des données dans le transcriptome consensus

Pour évaluer la quantité d'informations apporté par les 2 assembleurs les transcriptomes produit précédemment avec RNA-Bloom et rnaSPAdes, ont été aligné sur le transcriptome consensus final obtenu.




Figure 4 : Répartition des transcrits du transcriptome final de *P. parvum* retrouvés dans les assemblages RNA-Bloom et/ou rnaSPAdes (BLAST, identité ≥ 90 %, couverture ≥ 90 %).

Cette analyse montre que, parmi les transcrits du transcriptome final, 27,3 % (6,2 % + 21,1 %) présentent une similarité avec des séquences issues de RNA-Bloom, dont 6,2 % sont exclusivement présentes dans cet assemblage. Dans le transcriptome consensus final, 93,8 % (72,7 % + 21,1 %) des transcrits s'alignent avec des séquences issues de rnaSPAdes, dont 72,7 % sont exclusivement présentes dans cet assemblage (Figure 4).

Ces résultats mettent en évidence l'importance de l'assemblage rnaSPAdes dans le transcriptome final, qui représente plus de 93 % de l'information du transcriptome de *P. parvum*. Cela peut s'expliquer par une qualité et un nombre bien plus important de données short reads par rapport au données long reads.

4.5. Filtration et classification des ARN

Dans le but d'explorer la diversité des ARN présents dans le transcriptome produit, un module complémentaire a été ajouté au pipeline. Il permet à l'heure actuelle d'identifier les ARN messagers (ARNm), les ARN de transfert (ARNt) et les ARN ribosomaux (ARNr).

4.5.1. Séparation des ARN codants et non codants

Afin de distinguer les ARN codants des non-codants, une étape de séparation a été réalisée à partir du transcriptome final, en utilisant TransDecoder (Haas, B.J. – [GitHub TransDecoder](#)). C'est un outil conçu pour identifier les régions codantes potentielles (ORFs – Open Reading Frames) dans des transcrits issus d'un assemblage RNA-Seq. Le processus de TransDecoder commence par rechercher tous les ORFs d'une longueur suf-

fisante dans chaque transcrit. Ensuite, une évaluation de ces ORFs est réalisée et un score de log-vraisemblance mesurant la probabilité que la séquence observée corresponde à une vraie séquence codante plutôt qu'à une séquence aléatoire.

4.5.2. Identification des ARN ribosomaux

Pour l'identification des ARN ribosomaux, cette étude s'est focalisée sur trois ARNr formant le ribosome chez les eucaryotes : le 28S, le 18S et le 5,8S. La première étape consistait en l'obtention de bases de données spécifiques à ces ARNr. Les bases de données pour les ARNr 18S, 28S et 5,8S ont été obtenues grâce à la banque de données NCBI. Les jeux de séquences considérées comme non codantes ont ensuite été alignés avec les bases de données des ARNr à l'aide du module blastn (Camacho et al., 2009), et l'ensemble des séquences présentant un taux de correspondance inférieur ou égal à $1e-20$, seuil choisi pour éviter les faux positifs, a permis de créer un nouveau jeu de données correspondant aux ARNr.

4.5.3. Identification des ARN de transferts

L'identification des ARN de transfert a été réalisée à l'aide de l'outil tRNAscan-SE (Lowe & Eddy, 1997). Ce logiciel est conçu pour détecter les ARNt à partir de séquences d'ADN ou d'ARN. Dans un premier temps, une recherche des candidats dans l'ensemble des séquences non codantes (excluant les ARN ribosomaux) est effectuée grâce à la reconnaissance de motifs caractéristiques, connus et conservés. Ces candidats sont ensuite analysés à l'aide d'un modèle de covariance qui évalue à la fois la séquence et la structure en forme de trèfle typique des ARNt, permettant de discriminer les véritables ARNt. Enfin, les ARNt validés sont annotés automatiquement. L'outil identifie leur anticodon, ce qui permet de déterminer le type d'acide aminé transporté, et donc de classer les ARNt par isotype (par exemple ARNt(Phe), ARNt(Leu), etc.).

Les transcrits ayant passé toutes les étapes sans avoir pu être classés sont considérés comme non classifiés.

4.5.4. Évaluation de la distribution des ARN à travers les différents transcriptomes assemblés

L'assemblage Trinity est réalisé uniquement à partir des données short reads, ce qui entraîne la production d'un transcriptome constitué majoritairement de transcrits considérés comme codants (Tableau 5). Il contient moins de 1 % d'ARN ribosomaux et d'ARN de transfert.

En revanche, le transcriptome issu de rnaSPAdes présente une proportion plus faible d'ARNm (58,38 %) et une proportion d'ARN non classés bien supérieure à celle obtenue avec Trinity. Cela peut s'expliquer par l'intégration des long reads, qui a permis d'augmenter la proportion d'ARN non codants, tels que les ARNt et les ARN non classés.

Le transcriptome de RNA-Bloom est également composé majoritairement d'ARNm, mais environ 9,5 % des transcrits correspondent à des ARN ribosomaux et 29 % à des ARN non classés. Ces résultats mettent en évidence l'intérêt des long reads et des amorces random hexamers pour capturer une plus grande diversité de types d'ARN.

Enfin, les résultats du consensus montrent une réduction de l'ensemble des types d'ARN. Dans un premier temps, EvidentialGene est utilisé pour diminuer la redondance. Cependant, comme son approche est basée sur les ARN codants, l'amélioration du transcriptome pourrait s'accompagner d'une sélection privilégiée des ARNm et d'une suppression partielle des ARN non codants. Si on s'intéresse spécifiquement aux ARNs non messagers, il pourrait être judicieux d'exploiter les résultats d'assemblage de RNA-bloom et rnaSPAdes directement.

Tableau 5 : Tableau récapitulatifs du nombre d'ARN par type dans le transcriptome de *P. parvum* et leur provenance dans le transcriptome final.

Catégories	Trinity	rnaSPAdes	RNA-Bloom	Consensus
ARN totaux	94 937 (100 %)	104 341 (100 %)	26 992 (100 %)	61 553 (100 %)
ARN messagers	71 285 (75,07 %)	60 924 (58,38 %)	16 518 (61,18 %)	58 820 (95,07 %)
ARN ribosomaux	43 (0,045 %)	14 (0,013 %)	2 557 (9,47 %)	131 (0,21 %)
ARN de transferts	50 (0,053 %)	101 (0,097 %)	72 (0,27 %)	18 (0,029 %)
ARN non classés	23 559 (24,81 %)	43 302 (41,47 %)	7 845 (29,06 %)	2 884 (4,68 %)

L'utilisation d'EvidentialGene a permis de réduire la redondance sans impacter le score de complétude BUSCO, le score Bowtie2 et la proportion de transcrits s'alignant sur le transcriptome de référence. Concernant le nombre d'ARN codants par rapport à la littérature, le tableau 4 met en évidence que 95,07 % des transcrits (soit 58 820 séquences) sont classés comme ARN messagers. Il est estimé après l'annotation du génome que celui-ci comporte entre 19 000 et 25 000 gènes, cela correspondrait à environ 3 transcrits possibles pour un gène, ce qui est également estimé à partir de l'annotation du génome. Nous avons donc considéré que ce transcriptome de référence obtenu ici sans donnée génomique était de bonne qualité.

Ces résultats soulignent la complexité de l'assemblage de transcriptomes : aucun des outils testés ne fournit de résultats parfaits, chacun ayant ses avantages et ses limites. Toutefois, EvidentialGene, suivi d'un clustering avec CD-HIT-EST, apparaît comme une approche pertinente pour combiner les forces de RNA-Bloom et de rnaSPAdes, tout en réduisant fortement le nombre de transcrits générés par rnaSPAdes. Le nombre total de transcrits reste cependant élevé, et l'analyse des catégories d'ARN confirme la forte prédominance des ARN codants dans le transcriptome final.

5. Application du pipeline aux dinoflagellés

5.1. Mise en place du pipeline en production

Sur la base des résultats obtenus pour *P. parvum*, le pipeline présenté en Figure 5 a été retenu pour être appliqué à l'ensemble des espèces de dinoflagellés analysées dans cette étude.




Figure 5 : Schéma du pipeline final.

L'ensemble des scripts sont disponibles sur [Github](#). Ils ont été développés en Bash et dans le but d'être utilisés sur les infrastructures de l'Ifremer (Cluster HPC). Le dépôt est organisé en plusieurs dossiers, permettant soit d'utiliser les scripts de manière indépendante (dossier General), soit d'appliquer les scripts avec les paramètres utilisés dans le cadre de ce projet (dossier Custom).

Tableau 6 : Tableau résumé des statistiques d'assemblage produit à l'aide du pipeline pour chaque dinoflagellés.

	<i>K. veneficum</i>	<i>D. acuminata</i>	<i>L. polyedra</i>
Nombre d'ARN totaux	121 158	86 767	101 926
N50	1 652	882	1 793
Longueur max	17 218	8 288	15 763
Longueur min	196	196	196
Score BUSCO (alveolata)	97,1 %	80,07 %	95,9 %
Score Bowtie2	93,76%	81,43 %	95,73 %
Nombre d'ARN messagers	111 839 (92,33%)	82 918 (95,5%)	97 122 (95,28%)
Nombre d'ARN ribosomiaux	181 (0,15%)	5 (0,006%)	6 (0,006%)
Nombre d'ARN de transferts	6 (0,005%)	3 (0,003%)	2 (0,002%)
Nombre d'ARN non classés	9 132 (7,54%)	3 841 (4,43%)	4 796 (4,71%)

La méthode appliquée à *K. veneficum* a permis de générer un transcriptome consensus composé de 121 158 transcrits. Le score d'alignement Bowtie atteint 93,76%, indiquant une bonne représentativité des reads bruts dans l'assemblage final. La complétude évaluée par BUSCO est de 97,1 %, avec 57,3 % de gènes BUSCO uniques et 39,8 % de gènes dupliqués, ce qui témoigne également d'une bonne complétude du transcriptome.

Pour *D. acuminata*, le transcriptome consensus est composé de 86 767 transcrits. Les scores de qualité sont moins bons que ceux obtenus pour *K. veneficum*, avec 81,43 % des reads bruts qui s'alignent sur le transcriptome final, et un score de complétude BUSCO de 80,07 %, comprenant 52% de BUSCOs uniques et 28,7 % de BUSCOs dupliqués. Dans le cadre du projet de séquençage des eucaryotes microbiens marins (Keeling et al., 2014), un transcriptome de *D. acuminata* avait été assemblé à partir de données exclusivement issues de short reads. Celui-ci comptait 128 844 transcrits (soit 48 % de plus que

le nôtre) et présentait un score de complétude de 41,58 % sur la base de données eukaryota, contre 44,7 % pour le transcriptome obtenu dans cette étude sur cette même base.

Le transcriptome que nous présentons est donc constitué de moins de transcrits redondants, avec une valeur N50 plus élevée (882 pb contre 829 pb). Le score de complétude est également meilleur que celui rapporté dans la littérature, avec un taux de duplication plus faible (5,5 % contre 6,93 %).

Pour *L. polyedra* l'assemblage des long reads n'a pas été réalisé. Néanmoins, l'outil EvidentialGene a été appliqué au transcriptome produit par rnaSPAdes. Le transcriptome final obtenu est composé de 101 926 transcrits. Sur celui-ci 95,73 % des reads bruts s'alignent. Le score de complétude BUSCO atteint 95,9 %, avec 59,6 % de BUSCOs uniques et 36,3 % de BUSCOs dupliqués. (Meng et al., 2018) proposent également un assemblage de transcriptome pour *L. polyedra*, (uniquement à partir de short reads) composé de 143 704 transcrits, avec 92,6 % des reads bruts qui s'alignent sur le transcriptome et un score de complétude de 81,85 % calculé avec la base de données eukaryota. Lorsque l'assemblage produit dans ce projet est évalué avec cette même base, le score de complétude obtenu est de 74,9 %. Ainsi, bien que le score BUSCO soit légèrement inférieur à celui rapporté dans la littérature, la N50 (1 793 contre 1 386) est plus élevée dans notre assemblage, et la représentation des reads bruts est satisfaisante (95,73 %). La présence de long reads aurait potentiellement permis d'améliorer encore ces résultats.

5.2. Origine des ARNs dans les transcriptomes

Concernant la proportion de chaque type d'ARN dans les transcriptomes produits, les mêmes tendances sont observées : ils sont constitués majoritairement d'ARN messagers, représentant au minimum 92 % des transcrits. Les ARN de transfert et ribosomaux représentent chacun moins de 1 % du transcriptome final, tandis que 4 à 8 % des transcrits n'ont pas pu être classés.

Les transcriptomes produits pour chaque espèce présentent des scores de qualité globalement satisfaisants, ainsi qu'un nombre de transcrits conforme aux attentes pour les dinoflagellés.

6. Annotation fonctionnelles des transcriptomes

6.1. Annotation fonctionnelle du transcriptome

L'annotation fonctionnelle constitue une étape complémentaire pour évaluer la qualité des transcriptomes produits. Elle permet d'observer la richesse biologique du jeu de

données en vérifiant que les transcrits obtenus couvrent une diversité suffisante de fonctions cellulaires et métaboliques.

L'annotation fonctionnelle des transcriptomes a été réalisée avec Orson ([SeBiMER, 2021](#)) (prOteome and tRanScriptome functiOnal aNnotation). Conçu par la plateforme SeBiMER de l'Ifremer, il est en cours développement dans le cadre du projet Atlasea pour permettre l'annotation fonctionnelle d'espèces marines. Orson permet l'annotation de séquences nucléotidiques ou protéiques à partir de multiples bases de données d'informations biologiques. Le pipeline, adapté aux espèces marines, repose sur l'enchaînement suivant : dans un premier temps, les séquences du transcriptome ont été comparées à la base de données de référence DIAMOND afin de détecter les homologues potentiels et de produire un fichier d'alignement. Ce fichier est ensuite traité avec le module BeeDeeM, qui extrait automatiquement les annotations fonctionnelles associées aux séquences alignées. Les transcrits ont également été analysés avec InterProScan, qui identifie les domaines fonctionnels et structuraux au sein des protéines. Enfin, pour compléter l'annotation, le logiciel eggNOG-mapper a été utilisé pour rechercher des groupes orthologues et inférer des fonctions biologiques à partir d'homologues. À terme, la plateforme SeBiMER souhaite intégrer des approches basées sur la structure des protéines afin d'améliorer l'identification des fonctions.

La première étape du pipeline Orson consiste à rechercher, à l'aide de DIAMOND, les transcrits présentant un homologue dans les bases de référence. Chez les trois espèces de dinoflagellés étudiées, environ 40 % des transcrits ont un homologue identifié (Figure 6). La présence d'un homologue ne garantit pas qu'une fonction puisse être assignée : l'annotation fonctionnelle n'est réalisée que si l'homologue correspond à une entrée décrite dans les bases utilisées par Orson (InterProScan, eggNOG-mapper, etc.). Ainsi, à chaque étape de l'annotation, le nombre de transcrits annotés diminue. Parmi l'ensemble transcrits, 36 à 39 % contiennent un domaine protéique reconnu, et seulement 28 à 30 % peuvent se voir attribuer une fonction connue. L'annotation reste un défi majeur pour l'étude des transcriptomes, en particulier chez les organismes non modèles. Par exemple, l'annotation des transcrits de deux espèces de dinoflagellés, *Alexandrium minutum* et *Oxyrrhis marina* ont permis d'identifier une fonction pour seulement 28 % et 24 % des gènes respectivement (Akbar et al., 2018).

Cette limitation s'explique par les bases de données actuelles, qui sont majoritairement composées de séquences provenant d'organismes modèles bien étudiés (souris, Arabidopsis, homme etc.) mais bien loin des microalgues. Les dinoflagellés, issus d'une lignée évolutive éloignée, présentent une forte divergence par rapport à ces organismes, entraînant une faible similarité avec les séquences référencées. Rendant l'annotation par homologie particulièrement difficile. De plus, une grande partie des gènes des dinoflagellés est unique ou spécifique à cette lignée, ce qui limite encore la capacité d'annotation fonctionnelle.




Figure 6 : Pyramide représentant la répartition des transcrits selon le niveau de caractérisation fonctionnelle.

Concernant la richesse biologique des transcriptomes produits, bien que seulement 30 % des transcrits aient été annotés, les diverses fonctions attendues pour la survie de l'espèce sont observées (voir Figures S1, S2 et S3 en annexes). Pour les trois espèces, les fonctions sont présentes dans des proportions équivalentes, avec une prédominance de transcrits impliqués dans les processus cellulaires et la signalisation, notamment dans les mécanismes de transduction du signal, les modifications post-traductionnelles et le renouvellement des protéines.

7. Conclusion et perspectives

L'objectif de cette étude était de produire les transcriptomes les plus complets possibles pour trois espèces de dinoflagellés toxiques présentes dans les régions de Bretagne et des Pays de la Loire. La première étape a consisté en la production de données, et il a été constaté qu'au fil des séquençages, la qualité des long reads bruts s'est améliorée. Cette amélioration se reflète directement dans les transcriptomes, la proportion d'information apportée par les long reads dans le transcriptome final augmentant avec la qualité de ceux-ci. Cependant, le choix d'utiliser des long reads pour capturer l'entièreté du transcriptome des dinoflagellés n'a pas été aussi concluant qu'attendu notamment à cause de EvidentialGene qui favorise la présence de transcrits codants. D'un point de vue économique, il serait plus pertinent d'utiliser uniquement des short reads, éventuellement en combinant des amorces polyT et des amorces random hexamères dans un protocole hybride.

Différents outils ont ensuite été testés afin de mettre en place un pipeline capable de générer le transcriptome le plus complet pour ces trois espèces. La combinaison des assemblages RNA-BLOOM et rnaSPAdes, suivie d'EvidentialGene et d'un clustering avec CD-HIT, a permis de produire des transcriptomes de bonne qualité, avec un nombre de transcrits cohérent pour les dinoflagellés.

Enfin, l'évaluation de la richesse biologique des transcriptomes par annotation fonctionnelle avec Orson a permis d'identifier la fonction d'environ 30 % des transcrits. Cette proportion reste faible, mais elle est conforme aux attentes pour des espèces non modèles. Comme évoqué précédemment, l'annotation demeure un défi majeur dans l'étude des transcriptomes, en particulier pour les organismes non modèles, en raison de la distance phylogénétique entre les espèces utilisées pour constituer les bases de données et les espèces étudiées. Une approche complémentaire pourrait être l'utilisation des structures protéiques pour déterminer la fonction des gènes, mais cela nécessite un retour au laboratoire pour enrichir les bases de données de structures protéiques.

Cette étude met en évidence l'importance cruciale des données de référence, notamment d'un génome de référence, qui permettrait de compléter les bases de données utilisées par les différents outils. Des projets tels qu'Atlasea constituent des étapes essentielles pour améliorer la compréhension des dinoflagellés. Cependant, au vu de la taille du génome, leur assemblage reste incertain. Si jamais l'assemblage du génome de ces espèces sont un jour disponibles, ces données transcriptomiques produites ici seront précieuses pour réaliser l'annotation fonctionnelle. Les données produites dans ce projet peuvent également servir de référence pour d'autres études, et à l'avenir, le pipeline pourrait être amélioré et réutilisé pour fournir de nouvelles informations grâce à l'enrichissement progressif des bases de données.

Bibliographies

Barbosa, M., Costa, P. R., David, H., Lage, S., & Amorim, A. (2024). Effect of temperature on growth and yessotoxin production of *Protoceratium reticulatum* and *Lingulodinium polyedra* (Dinophyceae) isolates from the Portuguese coast (NE Atlantic). *Marine Environmental Research*, 194, 106321. <https://doi.org/10.1016/j.marenvres.2023.106321>

Beedessee, G., Kubota, T., Arimoto, A., Nishitsuji, K., Waller, R. F., Hisata, K., Yamasaki, S., Satoh, N., Kobayashi, J., & Shoguchi, E. (2020). Integrated omics unveil the secondary metabolic landscape of a basal dinoflagellate. *BMC Biology*, 18(1), 139. <https://doi.org/10.1186/s12915-020-00873-6>

Camacho, C., Coulouris, G., Avagyan, V., Ma, N., Papadopoulos, J., Bealer, K., & Madden, T. L. (2009). BLAST+: architecture and applications. *BMC Bioinformatics*, 10(1), 421. <https://doi.org/10.1186/1471-2105-10-421>

Chen, S. (2023). Ultrafast one-pass FASTQ data preprocessing, quality control, and deduplication using fastp. *IMeta*, 2(2), e107. <https://doi.org/10.1002/imt2.107>
de Vargas, C., Audic, S., Henry, N., Decelle, J., Mahé, F., Logares, R., Lara, E., Berney, C., Le Bescot, N., Probert, I., Carmichael, M., Poulain, J., Romac, S., Colin, S., Aury, J.-M., Bittner, L., Chaffron, S., Dunthorn, M., Engelen, S., ... Karsenti, E. (2015). Eukaryotic plankton diversity in the sunlit ocean. *Science*, 348(6237), 1261605. <https://doi.org/10.1126/science.1261605>

Jian, J., Wu, Z., Silva-Núñez, A., Li, X., Zheng, X., Luo, B., Liu, Y., Fang, X., Workman, C. T., Larsen, T. O., Hansen, P. J., & Sonnenschein, E. C. (2024). Long-read genome sequencing provides novel insights into the harmful algal bloom species *Prymnesium parvum*. *Science of The Total Environment*, 908, 168042. <https://doi.org/10.1016/j.scitotenv.2023.168042>

Keeling, P. J., Burki, F., Wilcox, H. M., Allam, B., Allen, E. E., Amaral-Zettler, L. A., Armbrust, E. V., Archibald, J. M., Bharti, A. K., Bell, C. J., Beszteri, B., Bidle, K. D., Cameron, C. T., Campbell, L., Caron, D. A., Cattolico, R. A., Collier, J. L., Coyne, K., Davy, S. K., ... Worden, A. Z. (2014). The Marine Microbial Eukaryote Transcriptome Sequencing Project (MMETSP): Illuminating the Functional Diversity of Eukaryotic Life in the Oceans through Transcriptome Sequencing. *PLOS Biology*, 12(6), e1001889. <https://doi.org/10.1371/journal.pbio.1001889>

Li, H. (2018). Minimap2: pairwise alignment for nucleotide sequences. *Bioinformatics*, 34(18), 3094-3100. <https://doi.org/10.1093/bioinformatics/bty191>

Li, W., & Godzik, A. (2006). Cd-hit: a fast program for clustering and comparing large sets of protein or nucleotide sequences. *Bioinformatics*, 22(13), 1658-1659. <https://doi.org/10.1093/bioinformatics/btl158>

- Lin, S. (2024). A decade of dinoflagellate genomics illuminating an enigmatic eukaryote cell. *BMC Genomics*, 25(1), 932. <https://doi.org/10.1186/s12864-024-10847-5>
- Lowe, T. M., & Eddy, S. R. (1997). tRNAscan-SE: A Program for Improved Detection of Transfer RNA Genes in Genomic Sequence. *Nucleic Acids Research*, 25(5), 955-964. <https://doi.org/10.1093/nar/25.5.955>
- Meng, A., Corre, E., Probert, I., Gutierrez-Rodriguez, A., Siano, R., Annamale, A., Alberti, A., Da Silva, C., Wincker, P., Le Crom, S., Not, F., & Bittner, L. (2018). Analysis of the genomic basis of functional diversity in dinoflagellates using a transcriptome-based sequence similarity network. *Molecular Ecology*, 27(10), 2365-2380. <https://doi.org/10.1111/mec.14579>
- Mutshinda, C. M., Finkel, Z. V., Widdicombe, C. E., & Irwin, A. J. (2016). Ecological equivalence of species within phytoplankton functional groups. *Functional Ecology*, 30(10), 1714-1722. <https://doi.org/10.1111/1365-2435.12641>
- Nakasugi, K., Crowhurst, R., Bally, J., & Waterhouse, P. (2014). Combining Transcriptome Assemblies from Multiple De Novo Assemblers in the Allo-Tetraploid Plant *Nicotiana benthamiana*. *PLoS ONE*, 9(3), e91776. <https://doi.org/10.1371/journal.pone.0091776>
- Nip, K. M. (2017). RNA-Bloom: de novo RNA-seq assembly with Bloom filters [University of British Columbia]. <https://doi.org/10.14288/1.0354248>
- Prjibelski, A. D., Puglia, G. D., Antipov, D., Bushmanova, E., Giordano, D., Mikhchenko, A., Vitale, D., & Lapidus, A. (2020). Extending rnaSPAdes functionality for hybrid transcriptome assembly. *BMC Bioinformatics*, 21(12), 302. <https://doi.org/10.1186/s12859-020-03614-2>
- Reguera, B., García-Portela, M., Velasco-Senovilla, E., Rial, P., Escalera, L., Díaz, P. A., & Rodríguez, F. (2024). Dinophysis, a highly specialized mixoplanktonic protist. *Frontiers in Protistology*, 1. <https://doi.org/10.3389/frpro.2023.1328026>
- Roy, S., & Morse, D. (2013). Transcription and Maturation of mRNA in Dinoflagellates. *Microorganisms*, 1(1), 71-99. <https://doi.org/10.3390/microorganisms1010071>
- Verma, A., Barua, A., Ruvindy, R., Savela, H., Ajani, P. A., & Murray, S. A. (2019). The Genetic Basis of Toxin Biosynthesis in Dinoflagellates. *Microorganisms*, 7(8), 222. <https://doi.org/10.3390/microorganisms7080222>
- Wang, R., Wu, J., Zhou, S., Cao, R., & Chan, L. L. (2020). A preliminary study on the allelopathy and toxicity of the dinoflagellate *Karlodinium veneticum*. *Marine Pollution Bulletin*, 158, 111400. <https://doi.org/10.1016/j.marpolbul.2020.111400>

Wick, R. (2025). rrwick/Porechop. <https://github.com/rrwick/Porechop> (Édition originale 2017)

Annexes




Figure S1 : Répartition des transcrits impliqués dans les processus cellulaires et la signalisation assignés a des fonctions pour les 3 espèces de dinoflagellés.




Figure S2 : Répartition des transcrits impliqués dans le métabolisme assignés a des fonctions pour les 3 espèces de dinoflagellés.

Catégorie COG : Stockage et traitement de l'information




Figure S3 : Répartition des transcrits impliqués dans le stockage et le traitement d'information assignés à des fonctions pour les 3 espèces de dinoflagellés.

Assemblage et caractérisation de transcriptomes de dinoflagellés

Mots clés : HAB, long reads, short reads,, annotation fonctionnelle

Les dinoflagellés sont des microalgues retrouvées dans différents habitats et impliquées dans les efflorescences d'algues toxiques et nuisibles (HAB). Ce groupe comprend un grand nombre d'espèces capables de produire des toxines nocives pour les écosystèmes et pour l'homme. Il s'agit d'organismes exotiques, au mode de vie et au génome complexes, encore peu étudiés, mais dont la surveillance est essentielle. Cette étude se concentre sur trois espèces de dinoflagellés responsables de HAB : *K. veneficum*, *L. polyedra* et *D. acuminata*. Pour ces organismes non modèles, il est nécessaire de produire des références génomique et transcriptomique permettant l'étude des mécanismes sous-jacents à la production de toxines et à la survie de ces espèces qui restent encore largement inconnus. L'objectif de ce projet était donc de générer les transcriptomes les plus complets possibles à partir de données long reads et short reads pour ces trois espèces de dinoflagellés. Pour cela, un pipeline a été mis en place, combinant les assembleurs RNA-Bloom et rnaSPAdes ainsi qu'EvidentialGene pour construire un transcriptome consensus, lui-même clusterisé par CD-HIT-EST. Les transcriptomes produits présentaient une bonne qualité, avec un score de complétude BUSCO d'au moins 80 %. Enfin, une annotation fonctionnelle a permis d'identifier la fonction d'environ 30 % des transcrits pour chaque transcriptome. Ces données constituent des références pour la communauté scientifique et pourront être utilisées dans des études complémentaires visant à mieux comprendre la biologie, la toxicité et la régulation des gènes de ces dinoflagellés.

Assembly and characterization of dinoflagellate transcriptomes

Key words : HAB, long reads, short reads, functional annotation

Dinoflagellates are microalgae found in various habitats and involved in harmful algal blooms (HABs). This group includes a large number of species capable of producing toxins that are harmful to ecosystems and humans. These are exotic organisms with complex lifestyles and genomes that have not yet been studied in depth, but whose monitoring is essential. This study focuses on three species of dinoflagellates responsible for HABs: *K. veneficum*, *L. polyedra*, and *D. acuminata*. For these non-model organisms, it is necessary to produce genomic and transcriptomic references to study the mechanisms underlying toxin production and survival of these species, which remain largely unknown. The objective of this project was therefore to generate the most complete transcriptomes possible from long read and short read data for these three species of dinoflagellates. To do this, a pipeline was set up, combining the RNA-Bloom and rnaSPAdes assemblers as well as EvidentialGene to build a consensus transcriptome, which was then clustered by CD-HIT-EST. The transcriptomes produced were of good quality, with a BUSCO completeness score of at least 80%. Finally, functional annotation identified the function of approximately 30% of the transcripts for each transcriptome. These data serve as references for the scientific community and may be used in further studies aimed at better understanding the biology, toxicity, and regulation of the genes of these dinoflagellates.